



ΕΘΝΙΚΟ ΚΑΙ ΚΑΠΟΔΙΣΤΡΙΑΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ

**ΣΧΟΛΗ ΘΕΤΙΚΩΝ ΕΠΙΣΤΗΜΩΝ
ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΤΗΛΕΠΙΚΟΙΝΩΝΙΩΝ**

ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ ΠΛΗΡΟΦΟΡΙΚΗ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

**Χρήση Αρχιτεκτονικών Transformer και Ενισχυτικής
Μάθησης με Μάθηση Μίμησης για το Πρόβλημα της
Πολυπρακτορικής Εύρεσης Μονοπατιών**

Γρηγόριος Ε. Μουλκιώτης

Επιβλέποντες: Παναγιώτης Σταματόπουλος, Επίκουρος Καθηγητής ΕΚΠΑ

ΑΘΗΝΑ

ΣΕΠΤΕΜΒΡΙΟΣ 2026

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Χρήση Αρχιτεκτονικών Transformer και Ενισχυτικής Μάθησης με Μάθηση Μίμησης για
το Πρόβλημα της Πολυπρακτορικής Εύρεσης Μονοπατιών

Γρηγόριος Ε. Μουλκιώτης
A.M.: 7115112400026

ΕΠΙΒΛΕΠΟΝΤΕΣ: Παναγιώτης Σταματόπουλος, Επίκουρος Καθηγητής ΕΚΠΑ

ΕΞΕΤΑΣΤΙΚΗ ΕΠΙΤΡΟΠΗ: Παναγιώτης Σταματόπουλος, Επίκουρος Καθηγητής ΕΚΠΑ
Κουμπάρακης Μανόλης, Καθηγητής ΕΚΠΑ
Παναγάκης Ιωάννης, Αναπληρωτής Καθηγητής ΕΚΠΑ

Ημερομηνία Εξέτασης: 1 Σεπτεμβρίου 2026

ΠΕΡΙΛΗΨΗ

Το πρόβλημα της πολυπρακτορικής εύρεσης μονοπατιών προέκυψε από την ανάγκη των ερευνητών να λύσουν το πρόβλημα της μετακίνησης πολλαπλών ρομπότ σε μια αποθήκη, τον χειρισμό της εναέριας κυκλοφορίας και των τραίνων. Η ραγδαία ανάπτυξη της βαθιάς μάθησης οδήγησε στη χρήση νευρωνικών δικτύων και στη δημιουργία του τομέα της βαθιάς ενισχυτικής μάθησης. Μια σύγχρονη προσέγγιση που χρησιμοποιείται στο πρόβλημα της πολυπρακτορικής εύρεσης μονοπατιών είναι η χρήση βαθιάς ενισχυτικής μάθησης με μάθηση μίμησης για τον προγραμματισμό των πρακτόρων δυναμικά, αντί για τη χρήση κλασικών αλγορίθμων αναζήτησης, οι οποίοι θα πρέπει να εκτελούνται σε κάθε αλλαγή εμποδίων ή του αριθμού των πρακτόρων και μειονεκτούν σε περίπτωση περιορισμένου οπτικού πεδίου. Μια τέτοια προσέγγιση αποτελεί το PRIMAL, το οποίο αξιοποιεί τον αλγόριθμο A3C και χρησιμοποιεί πολλαπλά Convolutional Neural Networks (CNN) για την εξαγωγή πληροφορίας και LSTM για τη λήψη αποφάσεων. Εκτός από ενισχυτική μάθηση χρησιμοποιείται καθοδήγηση από ειδικό μέσω του αλγόριθμου ODRM*, κάθε πράκτορας καθοδηγείται από ένα διάνυσμα που δείχνει προς τον στόχο του, καθώς και γνωρίζει τη θέση των άλλων πρακτόρων μέσα στο οπτικό του πεδίο. Στην παρούσα διπλωματική εργασία αρχικά συγκρίνουμε την απόδοση των νευρωνικών αρχιτεκτονικών Multilayer Perceptron, LSTM, GRU, Transformer για το πρόβλημα του MAPF μέσω μιας απλοποιημένης εκδοχής του PRIMAL. Οι πειραματισμοί μας οδήγησαν στην ανάπτυξη ενός αλγοριθμικού πλαισίου το οποίο χρησιμοποιεί Transformer για τη λήψη αποφάσεων και επικοινωνία από τους πράκτορες μαζί με μάθηση μίμησης, χρησιμοποιώντας Cooperative A*, έτσι ώστε να λαμβάνει γρήγορη καθοδήγηση από ειδικό και να επιταχύνει την εκπαίδευση. Επιπρόσθετα, για τη βελτιστοποίηση του αλγορίθμου, μελετήσαμε την αλληλεπίδραση των διαφορετικών συναρτήσεων ανταμοιβής στους αλγορίθμους PPO και A2C με την αποτελεσματικότητα των πρακτόρων στο πρόβλημα.

ΘΕΜΑΤΙΚΗ ΠΕΡΙΟΧΗ: Τεχνητή Νοημοσύνη

ΛΕΞΕΙΣ ΚΛΕΙΔΙΑ: Τεχνητή Νοημοσύνη, Πολυπρακτορική εύρεση μονοπατιών, Ενισχυτική Μάθηση, Βαθιά Μάθηση, Πολυπρακτορική Βαθιά Μάθηση

ABSTRACT

The problem of Multi-Agent Path Finding (MAPF) has emerged from the need to coordinate the movement of multiple robots in warehouses, as well as to address challenges in air traffic control and railway systems. The rapid growth of deep learning has led to the integration of neural networks with reinforcement learning, giving rise to the field of deep reinforcement learning. A modern approach that is used in the problem of MAPF is the combination of deep reinforcement learning and imitation learning to dynamically plan agents' paths, instead of using classic search algorithms, which must be re-executed for every change of obstacles or the number of agents and cannot solve the problem under partial observability. One such approach is PRIMAL which utilizes the A3C algorithm and employs multiple Convolutional Neural Networks (CNNs) to extract features/information and LSTM for the decision-making. In addition to Reinforcement Learning expert guidance is provided with ODRM* algorithm, each agent is guided by a vector that points toward its target and is aware of the positions of other agents within its field of view. In this thesis we evaluate the performance of Multilayer Perceptron (MLP), LSTM, GRU, and Transformer neural network architectures on the Multi-Agent Path Finding (MAPF) problem using a simplified version of PRIMAL. The experiments led to the development of an algorithmic flow that uses Transformer for decision-making and communication combined with Imitation Learning using Cooperative A* for fast guidance from expert and accelerated learning. Additionally, to optimize the algorithm, we studied the interaction of the different reward functions in PPO and A2C algorithms with the efficiency of the agents in the problem.

SUBJECT AREA: Artificial Intelligence

KEYWORDS: Artificial Intelligence, Multi-Agent Path Finding, Reinforcement Learning, Deep Learning, Multi-Agent Reinforcement Learning

Στην οικογένειά μου και τους φίλους μου.

ΕΥΧΑΡΙΣΤΙΕΣ

Θα ήθελα να ευχαριστήσω τον επιβλέποντα καθηγητή, Παναγιώτη Σταματόπουλο, για την καθοδήγησή και τις καίριες παρατηρήσεις του κατά τη διάρκεια της διπλωματικής εργασίας.

ΠΕΡΙΕΧΟΜΕΝΑ

1	ΕΙΣΑΓΩΓΗ	19
1.1	Στόχος και Προσέγγιση	19
1.2	Συνεισφορά	20
1.3	Δομή της διπλωματικής	20
2	ΥΠΟΒΑΘΡΟ ΚΑΙ ΣΧΕΤΙΚΕΣ ΕΡΕΥΝΕΣ	21
2.1	Multi-Agent Path Finding	21
2.1.1	One-Shot MAPF	21
2.1.1.1	Makespan	22
2.1.1.2	Sum-of-Costs (SoC)	22
2.1.2	Lifelong MAPF	22
2.1.3	Συγκεντρωμένες (Centralized)	22
2.1.4	Αποκεντρωμένες (Decentralized)	23
2.2	Κατηγορίες λύσεων για το MAPF	23
2.2.1	Μέθοδοι βασισμένες στην αναζήτηση (Search-Based)	23
2.2.1.1	Μέθοδοι βασισμένες στις συγκρούσεις (Conflict-Based Search – CBS)	23
2.2.1.2	Αναζήτηση βάσει προτεραιότητας (Priority-Based Search – PBS)	23
2.2.1.3	Large Neighborhood Search (LNS)	25
2.2.1.4	Lazy Constraints Addition search for MAPF (LaCAM)	26
2.2.2	Ενισχυτική μάθηση	26
2.2.2.1	Μαρκοβιανή διαδικασία λήψης αποφάσεων (Markov Decision Process – MDP)	27
2.2.2.2	Αλγόριθμοι Ενισχυτικής Μάθησης	28
2.2.3	Γενική αλγοριθμική ροή	31
2.2.3.1	Επιλογή συναρτήσεων ανταμοιβής	31
2.2.4	Πρόσφατες προσεγγίσεις στην Ενισχυτική Μάθηση	32
2.2.4.1	PRIMAL: Pathfinding via Reinforcement and Imitation Multi-Agent Learning	32
2.2.4.2	Confidence-Based Curriculum Learning for Multi-Agent Path Finding	32
2.2.4.3	MAPPER: Multi-Agent Path Planning with Evolutionary Reinforcement Learning in Mixed Dynamic Environments	33
2.2.4.4	Επικοινωνιακές Βελτιώσεις	33
2.3	Βαθιά Μάθηση	33
2.3.1	Multi Layer Perceptron (MLP)	34
2.3.2	Συνελκτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNN)	34
2.3.3	Recurrent Neural Network (RNN)	35

2.3.3.1	Long Short-Term Memory (LSTM)	35
2.3.3.2	Gated Recurrent Unit (GRU)	36
2.3.4	Transformer	37
3	ΜΕΘΟΔΟΛΟΓΙΑ	39
3.1	Frameworks	39
3.2	Curriculum Learning	39
3.3	Κατευθυνόμενη εκπαίδευση	39
3.3.1	LSTM	39
3.3.2	GRU	42
3.3.3	MLP	42
3.3.4	Μηχανισμοί Προσοχής (Transformers / Multi-Head Attention)	42
3.3.5	Καθοδήγηση μέσω του Cooperative A*	43
3.3.6	Εκπαίδευση	43
3.3.7	Αξιολόγηση	44
3.4	Αλγόριθμοι Βαθιάς Ενισχυτικής Μάθησης	45
3.5	Μη κατευθυνόμενη εκπαίδευση	45
4	Αποτελέσματα	47
4.1	Περιγραφή πειραματικής υποδομής	47
4.2	Χρήση καθοδήγησης	47
4.3	Αξιολόγηση συναρτήσεων ανταμοιβής	49
4.4	Αξιολόγηση νευρωνικών δικτύων	50
4.5	Αξιολόγηση αλγορίθμων Βαθιάς Ενισχυτικής Μάθησης	55
4.6	Απώλεια και Επιστροφή	55
5	ΣΥΜΠΕΡΑΣΜΑΤΑ ΚΑΙ ΜΕΛΛΟΝΤΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ	59
	ΣΥΝΤΜΗΣΕΙΣ – ΑΡΚΤΙΚΟΛΕΞΑ – ΑΚΡΩΝΥΜΙΑ	61
	APPENDICES	63
	ΑΝΑΦΟΡΕΣ	73

ΚΑΤΑΛΟΓΟΣ ΣΧΗΜΑΤΩΝ

3.1	Επίπεδο 6 με 32 πράκτορες. Για την εύρεση λύσης απαιτείται προηγμένη συνεργασία και επικοινωνία μεταξύ των πρακτόρων.	40
3.2	Επίπεδο 12 με 8 πράκτορες και πυκνότητα εμποδίων 20% του πλέγματος. Η επίλυση απαιτεί τόσο συνεργασία μεταξύ των πρακτόρων όσο και λήψη αποφάσεων όταν οι πράκτορες δρουν ανεξάρτητα.	41
4.1	Μέση τιμή του μήκους του μονοπατιού μεταξύ όλων των πρακτόρων του επεισοδίου για μάθηση με καθοδήγηση και χωρίς	48
4.2	Διαδοχή επιπέδων για μάθηση με καθοδήγηση και χωρίς	49
4.3	Διαδοχή επιπέδων για μάθηση με καθοδήγηση για τις διάφορες συναρτήσεις ανταμοιβής	51
4.4	Μέση τιμή του μήκους του μονοπατιού μεταξύ όλων των πρακτόρων του επεισοδίου για μάθηση με καθοδήγηση για τις διάφορες συναρτήσεις ανταμοιβής	52
4.5	Διαδοχή επιπέδων για μάθηση χωρίς καθοδήγηση	53
4.6	Εναλλαγή επιπέδων με τη χρήση διαφορετικών νευρωνικών δικτύων	54
4.7	Εναλλαγή επιπέδων με τη χρήση των αλγορίθμων A2C και PPO	55
4.8	Απώλεια κατά τη διάρκεια των δοκίμων με τη χρήση Transformer και A2C	56
4.9	Μέση επιστροφή από την αξιολόγηση με τη χρήση Transformer και A2C	56
1	Επίπεδο 1 - Ένας πράκτορας χωρίς εμπόδια	63
2	Επίπεδο 2 - Δύο πράκτορες χωρίς εμπόδια	64
3	Επίπεδο 3 - Τέσσερις πράκτορες χωρίς εμπόδια	64
4	Επίπεδο 4 - Οκτώ πράκτορες χωρίς εμπόδια	65
5	Επίπεδο 5 - Δεκαέξι πράκτορες χωρίς εμπόδια	65
6	Επίπεδο 6 - Τριανταδύο πράκτορες χωρίς εμπόδια	66
7	Επίπεδο 7 - Δύο πράκτορες με εμπόδια στο 10% του πλέγματος	66
8	Επίπεδο 8 - Τέσσερις πράκτορες με εμπόδια στο 10% του πλέγματος	67
9	Επίπεδο 9 - Οκτώ πράκτορες με εμπόδια στο 10% του πλέγματος	67
10	Επίπεδο 10 - Δύο πράκτορες με εμπόδια στο 20% του πλέγματος	68
11	Επίπεδο 11 - Τέσσερις πράκτορες με εμπόδια στο 20% του πλέγματος	68
12	Επίπεδο 12 - Οκτώ πράκτορες με εμπόδια στο 20% του πλέγματος	69
13	Επίπεδο 13 - Δύο πράκτορες με εμπόδια στο 30% του πλέγματος	69

ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ

3.1	Επίπεδα εκπαίδευσης κατά το Curriculum Learning	40
3.2	Συστατικά Συνάρτησης Ανταμοιβής	44
3.3	Συστατικά της συνάρτησης ανταμοιβής για την εκπαίδευση χωρίς καθοδήγηση	45
4.1	Μέσος αριθμός βημάτων και αριθμός επεισοδίων ανά επίπεδο με και χωρίς καθοδήγηση.	48
4.2	Σύγκριση των νευρωνικών δικτύων ανά επίπεδο	57

1. ΕΙΣΑΓΩΓΗ

Η ραγδαία ανάπτυξη της τεχνητής νοημοσύνης και της ρομποτικής έχει προσελκύσει το ενδιαφέρον των ερευνητών στην περιοχή της πολυπρακτορικής εύρεσης μονοπατιών (Multi Agent Path Finding) κατά την οποία μια ομάδα πρακτόρων πρέπει να σχεδιάσει τη διαδρομή της προς τον προορισμό. Εφαρμογές του προβλήματος του Multi-Agent Pathfinding (MAPF) αποτελούν η μεταφορά αγαθών με ρομπότ εντός μιας αποθήκης, ο χειρισμός της εναέριας κυκλοφορίας και η δρομολόγηση τράινων. Κλασική προσέγγιση στο πρόβλημα του MAPF αποτελούσε η χρήση αλγορίθμων αναζήτησης των οποίων ο κύριος περιορισμός είναι η απαίτηση γνώσης όλου του περιβάλλοντος. Με την ανάπτυξη των υπολογιστικών συστημάτων, ο τομέας της βαθιάς μάθησης γνώρισε άνθηση με τη χρήση των GPUs για την εκπαίδευση των μοντέλων. Σε αυτήν την κατεύθυνση προτάθηκαν λύσεις στο πρόβλημα του MAPF οι οποίες συνδυάζουν τη Βαθιά Μάθηση και την Ενισχυτική Μάθηση, κατά την οποία ο πράκτορας αναζητά το βέλτιστο μονοπάτι με βάση την ανταμοιβή που δέχεται από το περιβάλλον.

1.1 Στόχος και Προσέγγιση

Ο στόχος μας στην παρούσα διπλωματική εργασία είναι να δούμε πώς τα διαφορετικά νευρωνικά δίκτυα αποδίδουν στο πρόβλημα του MAPF. Η προσέγγισή μας είναι η κατασκευή ενός νευρωνικού δικτύου παρόμοιου με το PRIMAL [1] στο οποίο χρησιμοποιούμε ένα Συνελικτικό Νευρωνικό Δίκτυο για την εξαγωγή τοπικών χαρακτηριστικών, ένα Πλήρως Συνδεδεμένο Νευρωνικό δίκτυο που επεξεργάζεται το διάνυσμα που συνδέει τον πράκτορα με τον στόχο, οι πράκτορες επικοινωνούν μεταξύ τους με ένα επίπεδο επικοινωνίας γνωστοποιώντας την επόμενη τους κίνηση. Η συνενωμένη έξοδος τοπικών παρατηρήσεων και επικοινωνίας εισέρχεται σε ένα νευρωνικό δίκτυο (LSTM, GRU, Transformer, MLP) και προβλέπεται η επόμενη κίνηση του πράκτορα και το αναμενόμενο έπαθλο. Για την εκπαίδευση των πρακτόρων χρησιμοποιούμε Curriculum Learning για τη σταδιακή εκπαίδευσή τους. Με αυτήν την προσέγγιση προτείνουμε μια νέα αλγοριθμική ροή που χρησιμοποιεί Transformer, Μάθηση Μίμησης (Imitation Learning) και Ενισχυτική Μάθηση (Reinforcement Learning).

Επιπρόσθετα μελετήσαμε διαφορετικές συναρτήσεις ανταμοιβών και εξετάζουμε την αλληλεπίδρασή τους με τα διαφορετικά νευρωνικά δίκτυα και το Curriculum Learning. Οι συναρτήσεις που εξετάζουμε συνδυάζουν την ανταμοιβή για την επίτευξη του στόχου, την επίτευξη των στόχων των άλλων πρακτόρων, τη συμμόρφωση με το μονοπάτι που προτείνει ο ειδικός και την επιβολή ποινών σε περίπτωση σύγκρουσης με εμπόδια ή άλλους πράκτορες. Η υλοποίηση έγινε τόσο με τη χρήση των αλγορίθμων A2C και PPO και αναλύθηκε πόσο επιτάχυνε την εκπαίδευση η χρήση καθοδήγησης από ειδικό.

1.2 Συνεισφορά

Συνοψίζοντας, οι κύριες συνεισφορές της παρούσας διπλωματικής εργασίας είναι οι εξής:

1. Προτείνεται αλγοριθμικό πλαίσιο το οποίο χρησιμοποιεί Transformer με Μάθηση Μίμησης και Ενισχυτική Μάθηση για το πρόβλημα του MAPF.
2. Σύγκριση των διαφορετικών νευρωνικών δικτύων και των αλληλεπιδράσεών τους με το Curriculum Learning.
3. Μελέτη των διαφορετικών συναρτήσεων ανταμοιβής και της αλληλεπίδρασης τους με τη διαδοχή των επίπεδων στο Curriculum Learning.
4. Σύγκριση των A2C και PPO αλγορίθμων στο MAPF.
5. Ανάλυση της επιτάχυνσης της εκπαίδευσης από τη χρήση καθοδήγησης κατά τη μάθηση.

1.3 Δομή της διπλωματικής

Η υπόλοιπη διπλωματική οργανώνεται ως εξής; Στο δεύτερο κεφάλαιο αναλύεται το υπόβαθρο σχετικά με τα νευρωνικά δίκτυα, την Ενισχυτική Μάθηση καθώς και πρόσφατες δημοσιεύσεις στον τομέα του MAPF. Στο τρίτο κεφάλαιο παρουσιάζεται η μεθοδολογία που ακολουθούμε για μελέτη των μοντέλων νευρωνικών δικτύων και των συναρτήσεων ανταμοιβής. Στο τέταρτο κεφάλαιο εκτίθενται τα αποτελέσματα των δοκιμών και στο πέμπτο κεφάλαιο συνοψίζεται η διπλωματική, καθώς και οι μελλοντικές ερευνητικές προσπάθειες που μπορούν να γίνουν γύρω από αυτήν.

2. ΥΠΟΒΑΘΡΟ ΚΑΙ ΣΧΕΤΙΚΕΣ ΕΡΕΥΝΕΣ

2.1 Multi-Agent Path Finding

Ορίζουμε το πρόβλημα του Multi-Agent Path Finding (MAPF) [2] [3] ως εξής: Δεδομένων k πρακτόρων και ενός μη κατευθυνόμενου γράφου $G = (V, E)$, κάθε πράκτορας i πρέπει να εκκινήσει από μια αρχική θέση S_i και να καταλήξει σε μια θέση στόχο T_i . Σε κάθε χρονική στιγμή, όλοι οι πράκτορες είτε μετακινούνται σε μία γειτονική κορυφή του γράφου είτε παραμένουν στην ίδια θέση, δημιουργώντας κατ' αυτόν τον τρόπο ένα μονοπάτι $\pi = (a_1, a_2, \dots, a_n)$.

Κατά την εκτέλεση των μονοπατιών ενδέχεται να προκύψουν συγκρούσεις μεταξύ των πρακτόρων. Συνήθως, μια λύση θεωρείται έγκυρη όταν δεν υπάρχει καμία σύγκρουση μεταξύ των πρακτόρων. Οι συνηθέστερες κατηγορίες συγκρούσεων είναι οι ακόλουθες:

1. Σύγκρουση κορυφών (Vertex Conflict): Η σύγκρουση κορυφών συμβαίνει όταν δύο πράκτορες καταλαμβάνουν την ίδια κορυφή την ίδια χρονική στιγμή. Δεδομένων των μονοπατιών των πρακτόρων i και k , υπάρχει χρονική στιγμή x κατά την οποία ισχύει $\pi_i[x] = \pi_k[x]$.
2. Σύγκρουση εναλλαγής (Swapping Conflict): Η σύγκρουση εναλλαγής προκύπτει όταν δύο πράκτορες εναλλάσσουν τις θέσεις τους κατά την ίδια χρονική στιγμή, δηλαδή διασχίζουν την ίδια ακμή προς αντίθετες κατευθύνσεις. Δεδομένων των μονοπατιών π_i και π_k των πρακτόρων i και k , υπάρχει χρονική στιγμή x κατά την οποία ισχύει $\pi_i[x+1] = \pi_k[x]$ και $\pi_i[x] = \pi_k[x+1]$.
3. Κυκλική σύγκρουση (Cycle Conflict): Η κυκλική σύγκρουση συμβαίνει όταν μια ομάδα πρακτόρων μετακινείται κυκλικά, με αποτέλεσμα κάθε πράκτορας να καταλαμβάνει μια κορυφή που ήταν προηγουμένως κατειλημμένη από κάποιον άλλο πράκτορα. Δεδομένων των n μονοπατιών των πρακτόρων $\pi_1, \pi_2, \dots, \pi_n$, υπάρχει χρονική στιγμή x κατά την οποία ισχύει $\pi_1[x+1] = \pi_2[x]$, $\pi_2[x+1] = \pi_3[x]$, $\dots$, $\pi_{n-1}[x+1] = \pi_n[x]$ και $\pi_n[x+1] = \pi_1[x]$.

Επιπρόσθετα, το πρόβλημα του Multi-Agent Path Finding διακρίνεται σε δύο υποκατηγορίες: το One-Shot MAPF και το Lifelong MAPF.

2.1.1 One-Shot MAPF

Σε αυτήν την εκδοχή του προβλήματος, κάθε πράκτορας αρκεί να φτάσει στον προορισμό του ώστε να ολοκληρώσει τον σκοπό του. Για την αξιολόγηση της απόδοσης των λύσεων χρησιμοποιούνται είτε η συνάρτηση Makespan είτε η συνάρτηση Sum of Costs.

2.1.1.1 Makespan

Η συνάρτηση Makespan δέχεται ως όρισμα τα μονοπάτια όλων των πρακτόρων και επιστρέφει το μέγιστο κόστος διαδρομής μεταξύ όλων των πρακτόρων.

$$Makespan(\{\pi_i\}_{i=1}^n) = \max_{1 \leq i \leq n} Cost(\pi_i)$$

Με την ελαχιστοποίηση της συνάρτησης Makespan ελαχιστοποιείται και το μέγιστο κόστος διαδρομής μεταξύ όλων των πρακτόρων.

2.1.1.2 Sum-of-Costs (SoC)

Η συνάρτηση Sum-of-Costs (SoC) λαμβάνει ως όρισμα τα μονοπάτια όλων των πρακτόρων και επιστρέφει το άθροισμα των επιμέρους κοστών τους.

$$SoC(\{\pi_i\}_{i=1}^n) = \sum_{i=1}^n Cost(\pi_i)$$

Με την ελαχιστοποίηση της συνάρτησης SoC ελαχιστοποιείται και το συνολικό κόστος όλων των διαδρομών.

2.1.2 Lifelong MAPF

Η εκδοχή Lifelong του MAPF διαφοροποιείται από την One-Shot στο ότι οι πράκτορες δεν σταματούν όταν φτάσουν στον προορισμό τους, αλλά τους ανατίθενται συνεχώς νέες εργασίες. Συνεπώς, η προτεινόμενη μετρική αξιολόγησης είναι η μεγιστοποίηση του πλήθους των εργασιών που ολοκληρώνονται από όλους τους πράκτορες.

Μια ακόμη κατηγοριοποίηση των προσεγγίσεων του MAPF είναι ο διαχωρισμός τους σε συγκεντρωμένες και αποκεντρωμένες.

2.1.3 Συγκεντρωμένες (Centralized)

Στον συγκεντρωμένο έλεγχο, ένας καθολικός προγραμματιστής σχεδιάζει τα μονοπάτια για όλους τους πράκτορες, έχοντας πλήρη γνώση του περιβάλλοντος. Η προσέγγιση αυτή χρησιμοποιείται συνήθως για την εύρεση της βέλτιστης λύσης. Ωστόσο, ο προγραμματιστής πρέπει να επανασχεδιάζει τα μονοπάτια κάθε φορά που μεταβάλλεται ο αριθμός των πρακτόρων ή το περιβάλλον.

2.1.4 Αποκεντρωμένες (Decentralized)

Στον αποκεντρωμένο έλεγχο, κάθε πράκτορας σχεδιάζει το δικό του μονοπάτι. Η προσέγγιση αυτή εισάγει στο πρόβλημα τους περιορισμούς της μερικής παρατηρησιμότητας και της επικοινωνίας, καθώς οι πράκτορες δεν διαθέτουν πληροφορίες για ολόκληρο το περιβάλλον και πρέπει να συνεργαστούν προκειμένου να φτάσουν στους προορισμούς τους.

2.2 Κατηγορίες λύσεων για το MAPF

Οι προσεγγίσεις επίλυσης του προβλήματος MAPF χωρίζονται σε τέσσερις κατηγορίες: τις μεθόδους βασισμένες στην αναζήτηση (Search-Based), τις μεθόδους Compilation-Based, τις μεθόδους που βασίζονται στη μάθηση (Learning-Based) και τις υβριδικές μεθόδους.

2.2.1 Μέθοδοι βασισμένες στην αναζήτηση (Search-Based)

Οι μέθοδοι βασισμένες στην αναζήτηση αποτελούνται από αλγόριθμους αναζήτησης σε γράφους ή δενδρικές δομές, οι οποίοι αναζητούν μονοπάτια χωρίς συγκρούσεις για κάθε πράκτορα. Συνήθως οδηγούν στη βέλτιστη λύση. Ωστόσο, καθώς ο αριθμός των πρακτόρων αυξάνεται, οι μέθοδοι αυτές γίνονται ολοένα και πιο υπολογιστικά απαιτητικές.

2.2.1.1 Μέθοδοι βασισμένες στις συγκρούσεις (Conflict-Based Search – CBS)

Ο αλγόριθμος Conflict-Based Search (CBS) [4] αποτελεί τον θεμελιώδη αλγόριθμο της κατηγορίας των μεθόδων αναζήτησης. Αρχικά, πραγματοποιείται η αρχικοποίηση του δέντρου αναζήτησης και ο σχεδιασμός των μονοπατιών για κάθε πράκτορα. Στη συνέχεια, ελέγχεται αν υπάρχουν συγκρούσεις μεταξύ των μονοπατιών. Σε περίπτωση που εντοπιστεί σύγκρουση, δημιουργούνται νέοι περιορισμοί και επανασχεδιάζονται τα μονοπάτια των εμπλεκόμενων πρακτόρων με βάση αυτούς τους περιορισμούς. Η διαδικασία επαναλαμβάνεται μέχρι να βρεθεί μια λύση χωρίς συγκρούσεις. Ο αλγόριθμος παρουσιάζεται στον Αλγόριθμο 1.

2.2.1.2 Αναζήτηση βάσει προτεραιότητας (Priority-Based Search – PBS)

Η Priority-Based Search (PBS) [5] αποτελεί μία ακόμη θεμελιώδη προσέγγιση στις μεθόδους αναζήτησης για το πρόβλημα MAPF. Η κύρια διαφορά μεταξύ των αλγορίθμων CBS και PBS είναι ότι ο CBS δημιουργεί διακλαδώσεις για τους πράκτορες που εμπλέκονται σε μια σύγκρουση, ενώ ο PBS αναθέτει προτεραιότητες στους πράκτορες, είτε στατικά είτε δυναμικά. Με βάση αυτές τις προτεραιότητες, σχεδιάζεται το μονοπάτι κάθε πράκτορα,

Algorithm 1 Αλγόριθμος CBS

Require: Graph G , agents, start positions $\{s_i\}$, goal positions $\{t_i\}$
Create a conflict tree (CT) that will be used to store constraints, constraints for each agent are none.
For each agent plan its path to goal without taking into account potential collisions. This is the initial node of conflict tree.
Insert root node of the conflict tree into a priority queue.
while the priority queue is not empty **do**
 Pop the node with the most optimal solution.
 For all paths in node search for conflicts.
 if No conflict is found **then**
 the solution is returned
 else
 Find the first conflict.
 for each agent in the conflict **do**
 Create new node by copying the current.
 Append the constraint for this agent by forbidding moves in location of conflict
 this timestep
 Search for paths using the constraints created
 Insert the new node into the CT.
 end for
 end if
end while
if no solutions found return no solutions.

θεωρώντας ότι το μονοπάτι του πράκτορα με την υψηλότερη προτεραιότητα αποτελεί περιορισμό για τους πράκτορες χαμηλότερης προτεραιότητας. Ο αλγόριθμος παρουσιάζεται στον Αλγόριθμο 2.

Algorithm 2 Αλγόριθμος PBS

Require: Graph G , agents, start positions $\{s_i\}$, goal positions $\{t_i\}$
Create the priority ordering of agents.
for Each agent in descending priority **do**
 [Optional] dynamically change priorities if it is needed.
 Compute path for each agent treating other paths of higher priority ones as obstacles.
end for
Return the solutions for each agent.
if no solutions found return no solutions.

2.2.1.3 Large Neighborhood Search (LNS)

Η Large Neighborhood Search (LNS) [6] αποτελεί μία ακόμη προσέγγιση για την επίλυση του προβλήματος MAPF. Η κύρια διαφορά της σε σχέση με τον CBS είναι ότι η επίλυση των συγκρούσεων πραγματοποιείται σε τοπικό επίπεδο, μετά τον αρχικό σχεδιασμό των μονοπατιών, μέσω της μερικής ή ολικής ακύρωσης ορισμένων μονοπατιών και του επανασχεδιασμού τους. Με τον τρόπο αυτό, οι λύσεις βελτιστοποιούνται επαναληπτικά. Βελτιώσεις της μεθόδου LNS προτείνουν τη χρήση χρονικών ορίων κατά τη διαδικασία της βελτιστοποίησης, καθώς και την επανασχεδίαση μόνο των μονοπατιών που εισάγουν μεγάλο αριθμό συγκρούσεων. Ο αλγόριθμος παρουσιάζεται στον Αλγόριθμο 3.

Algorithm 3 Αλγόριθμος LNS

Require: Graph G , agents, start positions $\{s_i\}$, goal positions $\{t_i\}$, destroy ratio γ , max iterations κ
Create a first solution using any method.
for κ iterations **do**
 For a number of agents analogous to γ ratio invalidate part of their paths.
 For every agents whose path is invalidated re-plan their paths in order to minimize the cost.
 If the solution is better than the previous one use this as reference.
end for
Return the solutions for each agent.
If no solutions found return no solutions.

2.2.1.4 Lazy Constraints Addition search for MAPF (LaCAM)

Η LaCAM [7] αποτελεί έναν από τους πλέον σύγχρονους αλγόριθμους αναζήτησης για το πρόβλημα MAPF, καθώς είναι ιδιαίτερα επεκτάσιμη και αποδοτική ακόμη και για μεγάλο αριθμό πρακτόρων, επειδή αποφεύγει τη δημιουργία μεγάλου αριθμού διακλαδώσεων.

Ο αλγόριθμος αρχικά δημιουργεί μια ανοιχτή λίστα (Open List), η οποία περιέχει κόμβους υψηλού επιπέδου. Κάθε κόμβος αποθηκεύει μια διαμόρφωση, δηλαδή τις θέσεις όλων των πρακτόρων στον χάρτη, καθώς και ένα σύνολο περιορισμών, οι οποίοι καθορίζουν την επόμενη επιτρεπτή θέση κάθε πράκτορα. Στην αρχική δημοσίευση, η ανοιχτή λίστα υλοποιείται ως στοίβα. Στη συνέχεια, αρχικοποιείται η λίστα εξερεύνησης (Explored List), ώστε να αποφεύγεται η αποθήκευση της ίδιας διαμόρφωσης περισσότερες από μία φορές. Τόσο η ανοιχτή λίστα όσο και η λίστα εξερεύνησης αρχικοποιούνται με την αρχική διαμόρφωση του χάρτη.

Όσο η ανοιχτή λίστα δεν είναι κενή, αφαιρείται το τελευταίο στοιχείο της και αποθηκεύεται στον κόμβο N . Εάν η διαμόρφωση του N αντιστοιχεί στην επιθυμητή διαμόρφωση, τότε τα μονοπάτια ανακατασκευάζονται αναδρομικά. Εάν οι περιορισμοί του N είναι κενοί, ο αλγόριθμος προχωρά στον επόμενο κόμβο της ανοιχτής λίστας.

Οι περιορισμοί C περιέχουν πληροφορία χαμηλού επιπέδου και οργανώνονται σε μια δενδρική δομή, όπου κάθε κόμβος, εκτός από τη ρίζα, αντιστοιχεί σε έναν περιορισμό. Χρησιμοποιώντας τους περιορισμούς C του κόμβου N , ελέγχεται αν το βάθος του δέντρου C είναι μεγαλύτερο από τον αριθμό των πρακτόρων. Αν αυτό ισχύει, δεν δημιουργούνται νέοι κόμβοι για την αναζήτηση χαμηλού επιπέδου. Διαφορετικά, δημιουργούνται διάδοχοι του συγκεκριμένου κόμβου.

Στη συνέχεια, παράγεται μια νέα διαμόρφωση με βάση τον κόμβο και τους περιορισμούς. Εάν δεν είναι δυνατή η δημιουργία νέας διαμόρφωσης ή αυτή έχει ήδη εξερευνηθεί, ο αλγόριθμος προχωρά στον επόμενο κόμβο της ανοιχτής λίστας. Διαφορετικά, ο νέος κόμβος προστίθεται στην ανοιχτή λίστα. Ο αλγόριθμος παρουσιάζεται στον Αλγόριθμο 4.

2.2.2 Ενισχυτική μάθηση

Η Ενισχυτική Μάθηση (Reinforcement Learning - RL) [8] [9] [10] αποτελεί υποτομέα της Μηχανικής Μάθησης, στον οποίο οι πράκτορες δεν ακολουθούν έναν προκαθορισμένο αλγόριθμο, αλλά αλληλεπιδρούν με το περιβάλλον. Με βάση την ενέργεια που επιλέγουν σε κάθε χρονική στιγμή t , λαμβάνουν μια ανταμοιβή, η οποία αξιολογεί την ποιότητα των ενεργειών τους. Κατά τη διάρκεια της διαδικασίας μάθησης, οι πράκτορες επιδιώκουν να μεγιστοποιήσουν τη συνολική ανταμοιβή που λαμβάνουν.

Algorithm 4 LaCAM algorithm

Require: Graph G , agents, start positions $\{s_i\}$, goal positions $\{t_i\}$
 Create Open List containing high level nodes and constrains
 Create Explored Set
 Inside the Open and Explore push the initial configuration
while Open is not empty **do**
 Pop the Open List into the N
 If the N is the goal configuration backtrack and return the solution.
 If the N constrains are empty then pop the next item of Open and continue the while loop
 Inside C pop the constrains of node N
 If depth of C is greater than the number of agents do not create new node from this Node C otherwise create and add this to constrains of N
 Create new configuration using N and C and continue if we can not create an new one or Explored already contains it
 Push the new configuration into Open and Explored
end while
 If no solutions found return no solutions.

2.2.2.1 Μαρκοβιανή διαδικασία λήψης αποφάσεων (Markov Decision Process – MDP)

Ο κόσμος του προβλήματος MAPF μπορεί να μοντελοποιηθεί ως μια Μαρκοβιανή Διαδικασία Λήψης Αποφάσεων (Markov Decision Process - MDP), όπου κάθε κατάσταση S_{t+1} εξαρτάται αποκλειστικά από την προηγούμενη κατάσταση S_t και την ενέργεια που επιλέγεται σε αυτή. Τυπικά, ένα MDP ορίζεται ως:

$$\langle S_i, A_i, p(\cdot|\cdot), r_i, \gamma \rangle$$

- S_i είναι η κατάσταση του περιβάλλοντος που παρατηρεί ο πράκτορας i .
- A_i^t είναι το σύνολο των διαθέσιμων ενεργειών του πράκτορα i τη χρονική στιγμή t .
- $p(\cdot|\cdot)$ είναι η συνάρτηση πιθανοτήτων μετάβασης μεταξύ των καταστάσεων.
- r_i είναι η συνάρτηση ανταμοιβής του πράκτορα i .
- γ είναι ο συντελεστής έκπτωσης (discount factor), ο οποίος καθορίζει τη βαρύτητα των μελλοντικών ανταμοιβών. Συνήθως δίνεται μεγαλύτερη έμφαση στις άμεσες ανταμοιβές σε σχέση με τις μελλοντικές, λόγω της αβεβαιότητας του περιβάλλοντος.

Επομένως, η συνολική επιστροφή (return) για τον πράκτορα i ορίζεται ως

$$G_i = \sum_{t=0}^T \gamma^t r_i^t,$$

την οποία ο πράκτορας επιδιώκει να μεγιστοποιήσει μαθαίνοντας μια πολιτική $\pi(a|s)$, η οποία αντιστοιχίζει κάθε κατάσταση s σε μια ενέργεια a , ή ισοδύναμα σε μια κατανομή πιθανότητας πάνω στις διαθέσιμες ενέργειες.

2.2.2.2 Αλγόριθμοι Ενισχυτικής Μάθησης

Με στόχο οι πράκτορες να μάθουν τη βέλτιστη πολιτική, έχουν προταθεί διάφοροι αλγόριθμοι ενισχυτικής μάθησης. Στην παρούσα εργασία μελετώνται οι αλγόριθμοι Advantage Actor-Critic (A2C) και Proximal Policy Optimization (PPO).

Advantage Actor-Critic (A2C) Ο αλγόριθμος Advantage Actor-Critic (A2C) [11] αποτελείται από δύο βασικά στοιχεία: τον actor, ο οποίος επιλέγει την επόμενη ενέργεια, και τον critic, ο οποίος αξιολογεί την ποιότητα της επιλεγμένης ενέργειας. Με τον τρόπο αυτό διαχωρίζεται η διαδικασία λήψης αποφάσεων από τη διαδικασία αξιολόγησης.

Ορίζουμε τη συνάρτηση κατάστασης (state-value) $V(s)$, η οποία επιστρέφει την αναμενόμενη ανταμοιβή όταν ο πράκτορας βρίσκεται στην κατάσταση s και ακολουθεί την πολιτική π , καθώς και τη συνάρτηση δράσης-κατάστασης (action-value) $Q(s, a)$, η οποία επιστρέφει την αναμενόμενη ανταμοιβή όταν στην κατάσταση s επιλεγεί η δράση a . Οι δύο συναρτήσεις συνδέονται μέσω της σχέσης:

$$Q(s^t, a^t) = \begin{cases} r^t, & \text{if } s^{t+1} \text{ is terminal,} \\ r^t + \gamma V(s^{t+1}), & \text{otherwise.} \end{cases}$$

Επιπλέον, ορίζεται η συνάρτηση πλεονεκτήματος (advantage), η οποία είναι θετική όταν η δράση a αποδίδει καλύτερα από την αναμενόμενη και αρνητική όταν συμβαίνει το αντίθετο:

$$\text{Adv}^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$

Ο actor υλοποιείται ως νευρωνικό δίκτυο και εκπαιδεύεται ελαχιστοποιώντας τη συνάρτηση απώλειας

$$\mathcal{L}(\phi) = -\text{Adv}(s^t, a^t) \log \pi(a^t | s^t; \phi).$$

Αντίστοιχα, ο critic εκπαιδεύεται ελαχιστοποιώντας τη συνάρτηση απώλειας

$$\mathcal{L}(\theta) = (y^t - V(s^t; \theta))^2.$$

Με βάση τα παραπάνω, ο αλγόριθμος A2C παρουσιάζεται στον Αλγόριθμο 5.

Algorithm 5 A2C algorithm

```

Initialize the actor and critic neural networks with parameters  $\theta$  and  $\phi$ 
for EPISODES number of episodes do
  for  $t$  number of timesteps in episode do
    Observe the state of the environment
    Select action  $a$ 
    Apply action  $a$  in the environment, collect the reward and observe the next state
    if the next state is final then
       $\text{Adv}(s^t, a^t) \leftarrow r^t - V(s^t; \theta)$ 
       $y^t \leftarrow r^t$ 
    else
       $\text{Adv}(s^t, a^t) \leftarrow r^t + \gamma V(s^{t+1}; \theta) - V(s^t; \theta)$ 
       $y^t \leftarrow r^t + \gamma V(s^{t+1}; \theta)$ 
    end if
    Compute the actor loss  $\mathcal{L}(\phi) = -\text{Adv}(s^t, a^t) \log \pi(a^t | s^t; \phi)$ 
    Compute the critic loss  $\mathcal{L}(\theta) = (y^t - V(s^t; \theta))^2$ 
    Update parameters  $\phi, \theta$  in order to minimize the losses
  end for
end for

```

Proximal Policy Optimization (PPO) Στους αλγορίθμους Βαθιάς Ενισχυτικής Μάθησης, οι πολιτικές ενημερώνονται χρησιμοποιώντας μεθόδους gradient. Ωστόσο, κάθε ενημέρωση των παραμέτρων μπορεί να οδηγήσει σε σημαντική μεταβολή της πολιτικής, με αποτέλεσμα τη μείωση της αναμενόμενης απόδοσής της. Για την αντιμετώπιση αυτού του προβλήματος εισάγεται η έννοια των ζωνών εμπιστοσύνης (trust regions), οι οποίες περιορίζουν το μέγεθος της μεταβολής της πολιτικής μεταξύ δύο διαδοχικών ενημερώσεων.

Ο αλγόριθμος Proximal Policy Optimization (PPO) [12] αξιοποιεί την παραπάνω ιδέα ορίζοντας τον λόγο πιθανοτήτων (importance sampling ratio) ως

$$\rho(s, a) = \frac{\pi(a|s; \theta)}{\pi_{\beta}(a|s)}.$$

Όπου, για μια δεδομένη κατάσταση s και μια δράση a , η $\pi(a|s; \theta)$ είναι η πολιτική που επιδιώκεται να βελτιστοποιηθεί, ενώ η $\pi_{\beta}(a|s)$ είναι η πολιτική με την οποία συλλέχθηκαν τα δεδομένα εμπειρίας.

Χρησιμοποιώντας τα παραπάνω, ο αλγόριθμος PPO ακολουθεί την ίδια βασική δομή με τον A2C και παρουσιάζεται στον Αλγόριθμο 6.

Όπως μπορεί να παρατηρηθεί, ο αλγόριθμος χρησιμοποιεί N epochs, δηλαδή πραγματοποιεί πολλαπλές ενημερώσεις των παραμέτρων πάνω στο ίδιο batch δεδομένων. Επιπλέον, η συνάρτηση απώλειας του actor

Algorithm 6 PPO algorithm

Initialize the actor and critic neural networks with parameters θ and ϕ
for EPISODES number of episodes **do**
 for t number of timesteps in episode **do**
 Observe the state of the environment
 Select action a
 Apply action a in the environment, collect the reward and observe the next state
 Set $\pi_\beta(a|s) \leftarrow \pi(a|s; \theta)$
 for N number of epochs **do**
 $\rho(s, a) \leftarrow \frac{\pi(a|s; \theta)}{\pi_\beta(a|s)}$

 if the next state is final **then**
 $\text{Adv}(s^t, a^t) \leftarrow r^t - V(s^t; \theta)$
 $y^t \leftarrow r^t$
 else
 $\text{Adv}(s^t, a^t) \leftarrow r^t + \gamma V(s^{t+1}; \theta) - V(s^t; \theta)$
 $y^t \leftarrow r^t + \gamma V(s^{t+1}; \theta)$
 end if
 end for
 Compute the actor loss

 $\mathcal{L}(\phi) = -\min(\rho(s^t, a^t) \text{Adv}(s^t, a^t), \text{clip}(\rho(s^t, a^t), 1 - \epsilon, 1 + \epsilon) \text{Adv}(s^t, a^t))$

 Compute the critic loss $\mathcal{L}(\theta) = (y^t - V(s^t; \theta))^2$
 Update parameters ϕ, θ in order to minimize the losses
 end for
end for

$$\mathcal{L}(\phi) = - \min (\rho(s^t, a^t) \text{Adv}(s^t, a^t), \text{clip}(\rho(s^t, a^t), 1 - \epsilon, 1 + \epsilon) \text{Adv}(s^t, a^t))$$

περιλαμβάνει τον τελεστή clip, ο οποίος περιορίζει το μέγεθος των ενημερώσεων της πολιτικής. Με τον τρόπο αυτό αποτρέπονται μεγάλες μεταβολές στις παραμέτρους του actor, συμβάλλοντας στη σταθερότητα της εκπαίδευσης.

2.2.3 Γενική αλγοριθμική ροή

Οι περισσότερες σύγχρονες δημοσιεύσεις που χρησιμοποιούν Ενισχυτική Μάθηση για την επίλυση του προβλήματος MAPF ακολουθούν την ακόλουθη αλγοριθμική ροή:

1. Παρατήρηση: Σε αυτό το στάδιο, οι πράκτορες λαμβάνουν είτε τοπικές είτε συνολικές παρατηρήσεις, ανάλογα με το αν διαθέτουν περιορισμένο οπτικό πεδίο (Field of View – FOV). Επιπλέον, είναι δυνατόν να αξιοποιείται ιστορική πληροφορία όταν η εκπαίδευση πραγματοποιείται σε στατικό περιβάλλον ή με αποθηκευμένα δεδομένα εμπειρίας. Άλλες πληροφορίες που ενδέχεται να είναι διαθέσιμες περιλαμβάνουν τη θέση και την ταχύτητα των υπόλοιπων πρακτόρων, την απόσταση από τον προορισμό, καθώς και καθοδήγηση από κάποιον ειδικό, όπου παρέχεται στον πράκτορα το μονοπάτι που πρέπει να ακολουθήσει μέσω ενός αλγορίθμου.
2. Επεξεργασία χαρακτηριστικών (Feature Processing): Με τη χρήση συνελκτικών επιπέδων (convolutional layers) και μηχανισμών επικοινωνίας μεταξύ των πρακτόρων εξάγονται χαρακτηριστικά από τις διαθέσιμες παρατηρήσεις.
3. Δίκτυο πολιτικής (Policy Network): Το δίκτυο πολιτικής επεξεργάζεται τα εξαγόμενα χαρακτηριστικά και παράγει μια κατανομή πιθανοτήτων πάνω στις διαθέσιμες ενέργειες για κάθε πράκτορα.
4. Εκτέλεση ενέργειας: Κάθε πράκτορας εκτελεί την ενέργεια που επιλέχθηκε από το δίκτυο πολιτικής.
5. Συλλογή νέων παρατηρήσεων: Οι νέες παρατηρήσεις συλλέγονται και, όταν η εκπαίδευση πραγματοποιείται εκτός σύνδεσης (offline training), αποθηκεύονται σε έναν χώρο προσωρινής αποθήκευσης εμπειριών (replay buffer).

2.2.3.1 Επιλογή συναρτήσεων ανταμοιβής

Η επιλογή της συνάρτησης ανταμοιβής είναι καίριας σημασίας για την επιτυχία των πρακτόρων στο πρόβλημα του MAPF, καθώς βάσει αυτής οι πράκτορες θα πλοηγηθούν στο πλέγμα. Οι ανταμοιβές συνήθως περιλαμβάνουν:

- Επίτευξη στόχου: Η ανταμοιβή αυξάνεται σημαντικά όταν ο πράκτορας επιτυγχάνει τον στόχο του.

- Ποινή για σύγκρουση: Η ανταμοιβή μειώνεται όταν οι πράκτορες συγκρούονται.
- Καθοδήγηση από ειδικό: Η ανταμοιβή αυξάνεται όταν ο πράκτορας ακολουθεί το μονοπάτι που υποδεικνύει ο ειδικός.
- Συνεργασία: Η ανταμοιβή αυξάνεται όταν κάποιος άλλος πράκτορας επιτυγχάνει τον στόχο του.

2.2.4 Πρόσφατες προσεγγίσεις στην Ενισχυτική Μάθηση

2.2.4.1 PRIMAL: Pathfinding via Reinforcement and Imitation Multi-Agent Learning

Το PRIMAL: Pathfinding via Reinforcement and Imitation Multi-Agent Learning [1] [13] είναι η δημοσίευση που εγκαινίασε την έρευνα σχετικά με τη χρήση της Βαθιάς Ενισχυτικής Μάθησης για το πρόβλημα του MAPF και εξακολουθεί να χρησιμοποιείται ως σημείο αναφοράς (benchmark) για την αξιολόγηση νεότερων αλγορίθμων.

Η αρχιτεκτονική του PRIMAL βασίζεται σε μια συνάρτηση ανταμοιβής, η οποία αυξάνεται όταν ο πράκτορας επιτυγχάνει τον στόχο του και μειώνεται σε περιπτώσεις συγκρούσεων και μετακινήσεων. Επιπλέον, χρησιμοποιείται μάθηση μέσω μίμησης (Imitation Learning - IL), κατά την οποία κάθε πράκτορας λαμβάνει καθοδήγηση από έναν κεντρικό ειδικό. Στην υλοποίηση χρησιμοποιείται ο αλγόριθμος ODrM*.

Το περιβάλλον είναι μερικώς παρατηρήσιμο, ενώ ακολουθείται το σχήμα κεντρικής εκπαίδευσης και αποκεντρωμένης εκτέλεσης (Centralized Training and Decentralized Execution - CTDE).

Η αρχιτεκτονική του νευρωνικού δικτύου αποτελείται αρχικά από συνελκτικά νευρωνικά δίκτυα (CNNs) για την εξαγωγή χαρακτηριστικών από τις παρατηρήσεις, καθώς και από την πληροφορία σχετικά με την κατεύθυνση και την απόσταση του στόχου. Στη συνέχεια, τα εξαγόμενα χαρακτηριστικά εισάγονται σε πλήρως συνδεδεμένα επίπεδα (fully connected layers) και, τέλος, σε ένα δίκτυο LSTM, το οποίο παράγει τις κατανομές πιθανοτήτων των επόμενων δράσεων. Για την εκπαίδευση του μοντέλου χρησιμοποιείται ο αλγόριθμος A3C.

2.2.4.2 Confidence-Based Curriculum Learning for Multi-Agent Path Finding

Το Confidence-Based Auto-Curriculum for Team Update Stability (CACTUS) [14] προτείνει μια υπολογιστικά ελαφρύτερη προσέγγιση, η οποία βασίζεται στη μάθηση μέσω προγράμματος σπουδών (Curriculum Learning). Συγκεκριμένα, εφαρμόζεται μια διαδοχική διαδικασία εκπαίδευσης, κατά την οποία οι πράκτορες αρχίζουν την εκπαίδευσή τους σε περιβάλλοντα χαμηλής πολυπλοκότητας και στη συνέχεια προχωρούν σταδιακά σε περιβάλλοντα υψηλότερης πολυπλοκότητας.

Η συνάρτηση ανταμοιβής είναι απλούστερη σε σχέση με εκείνη του PRIMAL, αποδίδοντας ανταμοιβή +1 όταν ο πράκτορας φτάνει στον στόχο του και -1 σε κάθε άλλη περίπτωση.

Το νευρωνικό δίκτυο είναι επίσης απλούστερο, καταλαμβάνοντας λιγότερο από το 5% του χώρου που απαιτεί το αντίστοιχο δίκτυο του PRIMAL, ενώ αποτελείται αποκλειστικά από MLPs.

2.2.4.3 MAPPER: Multi-Agent Path Planning with Evolutionary Reinforcement Learning in Mixed Dynamic Environments

Το MAPPER: Multi-Agent Path Planning with Evolutionary Reinforcement Learning in Mixed Dynamic Environments (MAPPER) [15] προτείνει τη χρήση εξελικτικής ενισχυτικής μάθησης (Evolutionary Reinforcement Learning) με στόχο την επίτευξη καλύτερης υπολογιστικής κλιμάκωσης. Συγκεκριμένα, ένας πράκτορας εκπαιδεύεται χρησιμοποιώντας ένα σύνολο πολιτικών, τις οποίες αξιολογεί και στη συνέχεια ενημερώνει επαναληπτικά. Επιπλέον, αξιοποιείται ένας καθολικός προγραμματιστής μονοπατιών (global path planner), καθώς και συνελκτικά επίπεδα (convolutional layers) για την εξαγωγή πληροφοριών από το περιβάλλον.

2.2.4.4 Επικοινωνιακές Βελτιώσεις

Για την περαιτέρω βελτιστοποίηση των μονοπατιών των πρακτόρων απαιτείται η μεταξύ τους επικοινωνία.

Στην εργασία Ensembling Prioritized Hybrid Policies for Multi-agent Pathfinding (EPH) [16] προτείνεται η χρήση επιλεκτικής επικοινωνίας, όπου κάθε πράκτορας λαμβάνει πληροφορίες από τους πράκτορες που βρίσκονται εντός του οπτικού του πεδίου. Επιπλέον, προτείνεται η χρήση προηγμένων μηχανισμών λήψης αποφάσεων όταν οι πράκτορες δρουν μεμονωμένα, με στόχο την επίλυση αδιεξόδων και τη λήψη αποφάσεων βάσει προτεραιότητας, αξιοποιώντας νευρωνικά δίκτυα Q-Learning.

Η εργασία Optimizing Crowd-Aware Multi-Agent Path Finding through Local Communication with Graph Neural Networks (CRAMP) [17] προτείνει τη χρήση Νευρωνικών Δικτύων Γράφων (Graph Neural Networks - GNNs) για την επικοινωνία μεταξύ των πρακτόρων που βρίσκονται εντός του ορατού πεδίου τους, καθώς και τη χρήση Curriculum Learning για τη σταδιακή εκπαίδευσή τους.

Τέλος, η εργασία ALPHA: Attention-based Long-horizon Pathfinding in Highly-structured Areas [18] προτείνει τη χρήση τοπικής επικοινωνίας μέσω Graph Transformer, σε συνδυασμό με ακριβή τοπική πληροφορία και προσεγγιστική συνολική πληροφορία για το περιβάλλον.

2.3 Βαθιά Μάθηση

Οι εξελίξεις στη βαθιά μάθηση εισήγαγαν προσεγγίσεις βασισμένες στη μάθηση για την επίλυση του προβλήματος MAPF. Στην παρούσα ενότητα αναλύονται οι διαφορετικές αρ-

χιτεκτονικές βαθιάς μάθησης.

2.3.1 Multi Layer Perceptron (MLP)

Το Multi Layer Perceptron (MLP), γνωστό και ως Feed Forward Network (FFN), είναι ένα νευρωνικό δίκτυο που αποτελείται από διαδοχικά επίπεδα νευρώνων. Σε κάθε επίπεδο εφαρμόζονται συναρτήσεις ενεργοποίησης, οι οποίες εισάγουν μη γραμμικότητα στο μοντέλο. Κάθε επίπεδο περιέχει έναν αριθμό από κρυφούς νευρώνες. Τυπικά, το MLP μοντελοποιείται ως εξής:

Το κρυφό επίπεδο στη θέση d γράφεται ως:

$$h_d = a \left[\theta_{d0} + \sum_{i=1}^{D_i} \theta_{di} x_i \right]$$

Το επίπεδο εξόδου στη θέση j γράφεται ως:

$$y_j = a \left[\phi_{j0} + \sum_{d=1}^D \phi_{jd} h_d \right]$$

Συνεπώς, το MLP μοντελοποιείται ως:

$$y' = \phi'_0 + \sum_{n=1}^L \phi'_n y_n$$

2.3.2 Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNN)

Τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNN) αποτελούν έναν τύπο νευρωνικών δικτύων, στα οποία η είσοδος τροφοδοτείται αρχικά σε συνελικτικά επίπεδα (convolutional layers), στη συνέχεια σε επίπεδα συγκέντρωσης (pooling layers) και, τέλος, σε ένα πλήρως συνδεδεμένο επίπεδο (fully connected layer), από το οποίο προκύπτει η έξοδος.

Για μια διδιάστατη είσοδο (στην περίπτωση του MAPF, θα μπορούσε να είναι ένας χάρτης που περιλαμβάνει πράκτορες, προορισμούς και εμπόδια), το συνελικτικό επίπεδο μπορεί να μοντελοποιηθεί ως:

$$h_d = a \left[\beta + \sum_{n=1}^M \sum_{m=1}^M \omega_{mn} x_{i+m-c, j+n-c} \right]$$

όπου με ω συμβολίζεται ένας πυρήνας (kernel) διαστάσεων $M \times M$, ο οποίος λειτουργεί ως φίλτρο για την είσοδο, $c = \lfloor M/2 \rfloor + 1$, ενώ με a συμβολίζεται η συνάρτηση ενεργοποίησης.

Κατά τη φάση της συγκέντρωσης (pooling), η είσοδος υποδειγματοληπτείται με σκοπό τη μείωση των διαστάσεων της. Συνήθως επιλέγεται είτε η μέγιστη τιμή (Max Pooling) είτε η μέση τιμή (Average Pooling) των στοιχείων κάθε περιοχής.

Τα CNN χρησιμοποιούνται κυρίως στον τομέα της επεξεργασίας εικόνας για εργασίες όπως η αναγνώριση αντικειμένων, η επαλήθευση και αναγνώριση προσώπων, καθώς και η παραγωγή εικόνων. Στο πρόβλημα MAPF χρησιμοποιούνται για την εξαγωγή χαρακτηριστικών από τις παρατηρήσεις των πρακτόρων.

2.3.3 Recurrent Neural Network (RNN)

Τα Recurrent Neural Networks (RNN) [10] αποτελούν έναν τύπο νευρωνικών δικτύων, τα οποία δέχονται ως είσοδο όχι μόνο την τρέχουσα είσοδο αλλά και τις προηγούμενες εισόδους (ιστορική πληροφορία). Επιπλέον, το μέγεθος της εισόδου μπορεί να είναι μεταβλητό. Τα RNN μπορούν να μοντελοποιηθούν ως εξής:

Το κρυφό επίπεδο τη χρονική στιγμή t γράφεται ως:

$$h_t = a_h[\beta_h + W_{hh}h_{t-1} + W_{xh}x_t]$$

όπου a_h είναι η συνάρτηση ενεργοποίησης των κρυφών επιπέδων, β_h το bias των κρυφών επιπέδων και W_{hh}, W_{xh} τα βάρη που συσχετίζουν, αντίστοιχα, τα κρυφά επίπεδα μεταξύ τους και την είσοδο με τα κρυφά επίπεδα.

Η έξοδος τη χρονική στιγμή t υπολογίζεται ως:

$$y_t = a_y(\beta_y + W_{hy}h_t)$$

όπου a_y είναι η συνάρτηση ενεργοποίησης της εξόδου, W_{hy} τα βάρη που συσχετίζουν τα κρυφά επίπεδα με την έξοδο και β_y το αντίστοιχο bias.

Το κύριο πρόβλημα αυτής της προσέγγισης προκύπτει από το φαινόμενο των vanishing/exploding gradients, κατά το οποίο οι παράγωγοι τείνουν είτε να λαμβάνουν πολύ μικρές τιμές, με αποτέλεσμα το μοντέλο να μαθαίνει με αργό ρυθμό ή ακόμη και να μην μαθαίνει καθόλου, είτε να λαμβάνουν πολύ μεγάλες τιμές, γεγονός που καθιστά το μοντέλο ασταθές.

Ως λύση στο πρόβλημα αυτό προτείνονται τα Long Short-Term Memory (LSTM) και Gated Recurrent Unit (GRU), τα οποία αποτελούν υποτύπους των RNN. Στο πρόβλημα του MAPF, οι δύο αυτοί υποτύποι χρησιμοποιούνται συνήθως για τη λήψη αποφάσεων από τους πράκτορες, λαμβάνοντας υπόψη το ιστορικό των δράσεών τους.

2.3.3.1 Long Short-Term Memory (LSTM)

Η Long Short-Term Memory (LSTM) [19] αποτελεί έναν τύπο επαναλαμβανόμενου νευρωνικού δικτύου, ο οποίος αποθηκεύει πληροφορία μέσω κυψελωτών πυλών (gated cells).

Το LSTM μπορεί να μοντελοποιηθεί ως εξής:

Η πύλη εισόδου (input gate) γράφεται ως:

$$i_t = a[\beta_i + W_{xi}x_t + W_{hi}h_{t-1}]$$

Η πύλη εξόδου (output gate) γράφεται ως:

$$o_t = a[\beta_o + W_{xo}x_t + W_{ho}h_{t-1}]$$

Η πύλη λήθης (forget gate) γράφεται ως:

$$f_t = a[\beta_f + W_{xf}x_t + W_{hf}h_{t-1}]$$

Η νέα κατάσταση μνήμης εισάγεται ως:

$$\tilde{c}_t = a[\beta_c + W_{xc}x_t + W_{hc}h_{t-1}]$$

και συσχετίζεται με την προηγούμενη κατάσταση μνήμης ως:

$$c_t = i_t \odot \tilde{c}_t + f_t \odot c_{t-1}$$

Τέλος, το κρυφό επίπεδο γράφεται ως:

$$h_t = o_t \odot a[c_t]$$

2.3.3.2 Gated Recurrent Unit (GRU)

Τα Gated Recurrent Units (GRU) [20] [21] χρησιμοποιούν πύλες για την ενημέρωση της πληροφορίας μέσα στο κελί. Η πύλη ενημέρωσης (update gate) γράφεται ως:

$$z_t = a[\beta_z + W_{xz}x_t + W_{hz}h_{t-1}]$$

Επίσης, χρησιμοποιείται μια πύλη επαναφοράς (reset gate), μέσω της οποίας αναπαρίσταται η διατήρηση ή η απώλεια προηγούμενης πληροφορίας:

$$r_t = a[\beta_r + W_{xr}x_t + W_{hr}h_{t-1}]$$

Το υποψήφιο κρυφό επίπεδο συμβολίζεται ως:

$$\tilde{h}_t = a[\beta_h + W_{xh}x_t + W_{hr}(r_t \odot h_{t-1})]$$

Το τελικό κρυφό επίπεδο γράφεται ως:

$$h_t = (1 - z_t)h_{t-1} + z_t\tilde{h}_t$$

2.3.4 Transformer

Καθώς το μέγεθος της εισόδου αυξάνεται, τα νευρωνικά δίκτυα δυσκολεύονται να παρακολουθήσουν τις εξαρτήσεις και τις σχέσεις μεταξύ των στοιχείων. Για την αντιμετώπιση αυτού του προβλήματος, η εργασία "Attention Is All You Need" [22] προτείνει τη χρήση μηχανισμών προσοχής (attention), ώστε να αποθηκεύεται πληροφορία σχετικά με τη θέση και τη συσχέτιση των στοιχείων.

Η συνιστώσα της προσοχής αποτελείται από τα εξής:

Έναν πίνακα τιμών V , ο οποίος, δεδομένης της εισόδου X , μπορεί να γραφεί ως:

$$V[X] = \beta_V 1^T + W_V X$$

Στον πίνακα αυτό αποθηκεύεται η πληροφορία της εισόδου.

Επίσης, ορίζεται ένας πίνακας κλειδιών K , ο οποίος, δεδομένης της εισόδου X , σημειώνεται ως:

$$K[X] = \beta_K 1^T + W_K X$$

Ο πίνακας αυτός αποθηκεύει πληροφορία σχετικά με τις αποθηκευμένες εισόδους.

Ορίζεται επίσης ο πίνακας ερωτημάτων (query matrix) Q , ο οποίος, δεδομένης της εισόδου X , γράφεται ως:

$$Q[X] = \beta_Q 1^T + W_Q X$$

Ο πίνακας αυτός αποθηκεύει πληροφορία η οποία θα χρησιμοποιηθεί για την αναζήτηση σχετικών στοιχείων.

Με βάση αυτούς τους πίνακες δημιουργείται ο πίνακας αυτό-προσοχής (self-attention):

$$Sa[X] = V[X] \text{Softmax}\left[\frac{K[X]^T Q[X]}{\sqrt{d}}\right]$$

όπου με d συμβολίζεται η διάσταση των κλειδιών και των ερωτημάτων, έτσι ώστε η αυτό-προσοχή να μην επηρεάζεται αποκλειστικά από μεγάλες τιμές.

Χτίζοντας πάνω στον μηχανισμό αυτό-προσοχής, ένα επίπεδο Transformer δημιουργείται μέσω των ακόλουθων βημάτων:

Αρχικά, η είσοδος περνάει από ένα τμήμα αυτό-προσοχής. Συνήθως με πολλαπλές κεφαλές (multi-headed attention), ώστε να επιτυγχάνεται παράλληλη επεξεργασία και να αυξάνεται η σταθερότητα του μοντέλου σε περίπτωση μη βέλτιστης αρχικοποίησης.

Στη συνέχεια εφαρμόζεται ένα επίπεδο υπολειπόμενης σύνδεσης (Residual Layer), με στόχο τη βελτίωση της σταθερότητας κατά τη διάρκεια της εκπαίδευσης. Αυτό εκφράζεται ως:

$$X \leftarrow X + Sa[X]$$

$$X \leftarrow LayerNorm[X]$$

Έπειτα, τα αποτελέσματα εισάγονται σε ένα Feedforward Network, όπου κάθε είσοδος επεξεργάζεται παράλληλα και εφαρμόζεται εκ νέου κανονικοποίηση στην έξοδο:

$$x_n \leftarrow x_n + mlp[x_n] \quad \forall n \in X$$

$$X \leftarrow LayerNorm[X]$$

Οι Transformers έχουν εφαρμογές στην επεξεργασία φυσικής γλώσσας (Natural Language Processing - NLP) [22], στην υπολογιστική όραση [23] [24] και μελετώνται επί του παρόντος στον τομέα του MAPF. Μία από τις πιο ενδιαφέρουσες δημοσιεύσεις είναι η MAPF-GPT [25], όπου ένα νευρωνικό δίκτυο βασισμένο στη δομή των Transformers εκπαιδεύεται χρησιμοποιώντας ένα μεγάλο σύνολο δεδομένων από μονοπάτια που παράγονται από το LaCAM.

3. ΜΕΘΟΔΟΛΟΓΙΑ

3.1 Frameworks

Για την αξιολόγηση της απόδοσης των διαφόρων νευρωνικών δικτύων χρησιμοποιήθηκε η βιβλιοθήκη βαθιάς μάθησης PyTorch [26], στην οποία υλοποιήθηκαν οι αρχιτεκτονικές των νευρωνικών δικτύων.

Επιπρόσθετα, για τη μοντελοποίηση του προβλήματος MAPF χρησιμοποιήθηκε το POGEMA [27], το οποίο παρέχει ένα περιβάλλον πλέγματος όπου ο πράκτορας μπορεί να παρατηρεί μερικώς το περιβάλλον. Η προσέγγιση αυτή επιτρέπει στους ερευνητές να δοκιμάζουν αλγορίθμους πολλαπλών πρακτόρων σε ένα κοινό περιβάλλον.

Επιπλέον, η χρήση της γλώσσας προγραμματισμού Python για την υλοποίησή του διευκολύνει την επέκταση του framework, εφόσον αυτό απαιτηθεί.

3.2 Curriculum Learning

Σε όλες τις δοκιμές χρησιμοποιείται Curriculum Learning, κατά το οποίο η εκπαίδευση ξεκινά από την κίνηση ενός πράκτορα χωρίς εμπόδια. Στη συνέχεια, προστίθενται σταδιακά περισσότεροι πράκτορες και, τέλος, εισάγονται εμπόδια στον χάρτη.


Η προσέγγιση αυτή βοηθά τους πράκτορες να μάθουν σταδιακά τον τρόπο με τον οποίο πρέπει να κινούνται στον χάρτη, καθώς και να αναπτύξουν ικανότητες συνεργασίας. Στη συνέχεια παρουσιάζονται τα επίπεδα εκπαίδευσης που χρησιμοποιήθηκαν στο πλαίσιο του Curriculum Learning. Επιπλέον, αναπαραστάσεις των επιπέδων εκπαίδευσης παρατίθενται στο Παράρτημα.

3.3 Κατευθυνόμενη εκπαίδευση

3.3.1 LSTM

Η αρχική μας προσέγγιση βασίζεται σε αυτή του PRIMAL [1], όπου χρησιμοποιείται ένα νευρωνικό δίκτυο αποτελούμενο από τα ακόλουθα στάδια:

1. Συνελικτικό Νευρωνικό Δίκτυο (Convolutional Neural Network – CNN): Αρχικά, το πεδίο ορατότητας (Field of View – FOV) του πράκτορα εξάγεται από το POGEMA. Η παρατήρηση αναπαρίσταται ως ένας τανυστής που αποτελείται από τρεις δυαδικούς πίνακες διαστάσεων $(2R + 1) \times (2R + 1)$, όπου το R δηλώνει την ακτίνα παρατήρησης. Ο πρώτος πίνακας περιέχει τα εμπόδια, ο δεύτερος τις θέσεις των υπόλοιπων πρακτόρων και ο τρίτος την προβολή του στόχου. Ο τανυστής αυτός εισάγεται σε



Σχήμα 3.2: Επίπεδο 12 με 8 πράκτορες και πυκνότητα εμποδίων 20% του πλέγματος. Η επίλυση απαιτεί τόσο συνεργασία μεταξύ των πρακτόρων όσο και λήψη αποφάσεων όταν οι πράκτορες δρουν ανεξάρτητα.

ένα Συνελικτικό Νευρωνικό Δίκτυο (CNN), από το οποίο εξάγονται τοπικά χωρικά χαρακτηριστικά.

2. Πλήρως συνδεδεμένο δίκτυο προορισμού (Goal FC): Παράλληλα, το διάνυσμα απόστασης του πράκτορα από τον τελικό προορισμό του εισάγεται σε ένα πλήρως συνδεδεμένο επίπεδο (Linear layer), παράγοντας μια διανυσματική αναπαράσταση του στόχου. Η αναπαράσταση αυτή συνενώνεται με τα χαρακτηριστικά του CNN, δημιουργώντας τη συνολική τοπική αναπαράσταση (local features).
3. Επίπεδο επικοινωνίας (Communication Layer): Το επίπεδο αυτό επιτρέπει την ανταλλαγή πληροφοριών μεταξύ των πρακτόρων. Κάθε πράκτορας παράγει ένα μήνυμα με βάση την τρέχουσα τοπική του αναπαράσταση. Στη συνέχεια, τα μηνύματα όλων των πρακτόρων συγκεντρώνονται μέσω της τεχνικής mean pooling, δημιουργώντας ένα καθολικό μήνυμα, το οποίο αναμεταδίδεται (broadcast) σε όλους τους πράκτορες.
4. Δίκτυο Μακράς Βραχύχρονης Μνήμης (Long Short-Term Memory – LSTM): Η συνενωμένη έξοδος της τοπικής αναπαράστασης και του καθολικού μηνύματος επικοινωνίας εισάγεται σε ένα επίπεδο LSTM. Τέλος, από την έξοδο του LSTM, δύο ξεχωριστές κεφαλές (Linear layers) παράγουν τις πιθανότητες επιλογής της επόμενης ενέργειας (policy logits) και την εκτιμώμενη αξία της τρέχουσας κατάστασης (state value).

3.3.2 GRU

Με βάση τα αποτελέσματα της εργασίας Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling[28], δοκιμάστηκε μια εναλλακτική προσέγγιση σε σχέση με το PRIMAL. Συγκεκριμένα, στο τελευταίο στάδιο του δικτύου το επίπεδο LSTM αντικαταστάθηκε από μια μονάδα Gated Recurrent Unit (GRU).

3.3.3 MLP

Ακολουθώντας την προσέγγιση του CACTUS [14], αντικαταστάθηκε στο τελευταίο στάδιο του δικτύου το επίπεδο LSTM από ένα απλούστερο δίκτυο Multi-Layer Perceptron (MLP).

3.3.4 Μηχανισμοί Προσοχής (Transformers / Multi-Head Attention)

Εμπνεόμενοι από το MAPF-GPT [25], πειραματιστήκαμε με τη χρήση μηχανισμών αυτοπροσοχής (Self-Attention) για την επίλυση του προβλήματος MAPF. Στην προσέγγιση αυτή, η επικοινωνία μεταξύ των πρακτόρων βασίζεται σε ένα επίπεδο Multi-Head Attention, το οποίο αντικαθιστά την απλή καθολική συνάθροιση μέσω mean pooling. Οι διανυσματικές αναπαραστάσεις όλων των πρακτόρων εισάγονται σε ένα επίπεδο Multi-Head Self-Attention. Με τον τρόπο αυτό, κάθε πράκτορας μπορεί να εστιάζει επιλεκτικά σε διαφορετικούς γειτονικούς πράκτορες ή πιθανές απειλές, αποδίδοντας διαφορετικά βάρη στα μηνύματά τους. Η έξοδος του επιπέδου αυτοπροσοχής σταθεροποιείται μέσω επιπέδων Layer Normalization και υπολειμματικών συνδέσεων (residual connections) και στη συνέχεια εισάγεται σε ένα Feed-Forward Network.

Algorithm 7 Decentralized Communication Reinforcement Learning System with Imitation Learning Guidance

Require: Total training episodes M , discount factor γ , entropy coefficient β , learning rate α , expert imitation coefficient λ , initial curriculum level $\ell = 0$, episode length N
Initialize network parameter weights θ
Initialize adaptive environment configuration map and construct environment
for episode = 1 to M **do**
 Reset the environment and get the active configuration
 for episode length = 1 to N **do**
 Get Goal Vector
 Get Observations
 Query the Expert for guidance targets
 Using the Neural Network export the logits of every action
 Chose the next action
 Execute the action
 Collect the reward
 Update phase using the A2C or PPO
 Calculate value returns with Monte Carlo Bellman tracking
 Calculate the losses
 Execute backpropagation
 end for
end for

3.3.5 Καθοδήγηση μέσω του Cooperative A*

Στη δημοσίευση του PRIMAL χρησιμοποιείται ο αλγόριθμος ODRM* [29] για την καθοδήγηση των πρακτόρων κατά την κίνησή τους στο πλέγμα. Στην παρούσα εργασία χρησιμοποιείται ο αλγόριθμος Cooperative A* [30] για την εύρεση μονοπατιού από κάθε πράκτορα προς τον στόχο του. Συγκεκριμένα, αρχικά υπολογίζεται το μονοπάτι κάθε πράκτορα με τον αλγόριθμο A* και στη συνέχεια χρησιμοποιείται ο αλγόριθμος PBS για την επίλυση των συγκρούσεων που ενδέχεται να προκύψουν μεταξύ των μονοπατιών. Η προτεραιότητα των πρακτόρων καθορίζεται κατά την αρχικοποίηση και παραμένει σταθερή καθ' όλη τη διάρκεια της εκτέλεσης.

3.3.6 Εκπαίδευση

Ορίζεται ένας αριθμός επεισοδίων κατά τον οποίο εκπαιδεύονται οι πράκτορες στα επίπεδα του curriculum. Στην αρχή κάθε επεισοδίου το περιβάλλον επαναφέρεται στην αρχική του κατάσταση και, για προκαθορισμένο αριθμό χρονικών βημάτων, οι πράκτορες εκτελούν ενέργειες μέσα στον χάρτη. Λόγω περιορισμένων υπολογιστικών πόρων, κάθε πράκτορας μπορεί να εκτελέσει έως 256 κινήσεις.

Κατά την εκτέλεση των ενεργειών, κάθε πράκτορας παρατηρεί τα εμπόδια που βρίσκονται

εντός του πεδίου ορατότητάς του, καθώς και το διάνυσμα που τον συνδέει με τον στόχο. Επιπλέον, παράγονται μονοπάτια με τον Cooperative A*, τα οποία χρησιμοποιούνται τόσο για τη διαμόρφωση των συναρτήσεων ανταμοιβής όσο και για τον υπολογισμό της συνάρτησης απώλειας.

Μετά από κάθε εκτέλεση ενέργειας συλλέγονται οι ανταμοιβές όλων των πρακτόρων. Για τους σκοπούς της πειραματικής αξιολόγησης χρησιμοποιούνται τέσσερις διαφορετικές συναρτήσεις ανταμοιβής. Η πρώτη συνάρτηση περιλαμβάνει ανταμοιβή για την επίτευξη του στόχου και ποινή για τις συγκρούσεις. Η δεύτερη προσθέτει επιπλέον ανταμοιβή όταν οι ενέργειες ενός πράκτορα ευθυγραμμίζονται με αυτές που προτείνει ο ειδικός. Η τρίτη συνάρτηση ανταμείβει επιπλέον τον πράκτορα όταν κινείται προς τον στόχο, ενώ η τέταρτη παρέχει πρόσθετη ανταμοιβή όταν και άλλοι πράκτορες φτάνουν στους στόχους τους, εκτός από τον υπό εξέταση πράκτορα.

Στο τέλος κάθε επεισοδίου υπολογίζεται η συνάρτηση απώλειας και ενημερώνονται τα βάρη του μοντέλου.

Πίνακας 3.2: Συστατικά Συνάρτησης Ανταμοιβής

Συστατικό ανταμοιβής	Τιμή
Επίτευξη στόχου	+2.00
Κίνηση προς τον στόχο	+0.01
Κίνηση μακριά τον στόχο	-0.01
Σύγκρουση	-0.05
Ταύτιση δράσης με αυτήν του ειδικού	+0.10
Μη ταύτιση δράσης με αυτήν του ειδικού	-0.02
Άλλος πράκτορας έφτασε στον στόχο του	+0.50 για κάθε πράκτορα

3.3.7 Αξιολόγηση

Για να αξιολογηθεί κατά πόσο οι πράκτορες έχουν μάθει να εκτελούν τις κατάλληλες ενέργειες και μπορούν να μεταβούν στο επόμενο επίπεδο του curriculum, ορίζεται ένα διάστημα εκπαίδευσης, το οποίο στην παρούσα εργασία αντιστοιχεί σε 100 επαναλήψεις. Μετά την ολοκλήρωση αυτού του διαστήματος πραγματοποιείται διαδικασία αξιολόγησης.

Κατά την αξιολόγηση η εκπαίδευση διακόπτεται και οι ενέργειες των πρακτόρων επιλέγονται βάσει της μεγαλύτερης πιθανότητας που παράγει το δίκτυο πολιτικής. Αντίθετα, κατά τη διάρκεια της εκπαίδευσης οι ενέργειες δειγματοληπτούνται από την κατανομή πιθανοτήτων, ώστε να ευνοείται η εξερεύνηση του περιβάλλοντος.

Η αξιολόγηση πραγματοποιείται σε 10 επεισόδια, κατά τα οποία καταγράφονται η μέση διάρκεια των επεισοδίων, η μέση ανταμοιβή των πρακτόρων και το ποσοστό επιτυχίας. Εφόσον το ποσοστό επιτυχίας υπερβεί ένα προκαθορισμένο όριο, οι πράκτορες προχωρούν στο επόμενο επίπεδο. Στην παρούσα εργασία το όριο αυτό ορίζεται στο 80%.

3.4 Αλγόριθμοι Βαθιάς Ενισχυτικής Μάθησης

Η παραπάνω διαδικασία εφαρμόζεται τόσο στον αλγόριθμο A2C όσο και στον PPO. Και στις δύο περιπτώσεις η συνολική συνάρτηση απώλειας ορίζεται ως:

$$\mathcal{L} = \mathcal{L}_{\text{actor}} + \sigma \mathcal{L}_{\text{critic}} - \beta \mathcal{L}_{\text{entropy}} + \lambda \mathcal{L}_{\text{IL}} \quad (3.1)$$

Όπου $\mathcal{L}_{\text{entropy}}$ είναι ο όρος κανονικοποίησης εντροπίας, ο οποίος χρησιμοποιείται για να ενισχύσει την εξερεύνηση του περιβάλλοντος και να αποτρέψει την πρόωρη σύγκλιση των πρακτόρων σε μία πολιτική.

Ο όρος $\mathcal{L}_{\text{IL}}$ αντιστοιχεί στην απώλεια της μίμησης (Imitation Learning) και εκφράζει τη διαφορά μεταξύ των ενεργειών που προτείνει ο ειδικός και αυτών που επιλέγει το μοντέλο. Στόχος του είναι να καθοδηγήσει το μοντέλο ώστε να παράγει ενέργειες όσο το δυνατόν πιο κοντά σε αυτές του ειδικού.

3.5 Μη κατευθυνόμενη εκπαίδευση

Για να αξιολογηθεί η απόδοση των προτεινόμενων νευρωνικών δικτύων χωρίς καθοδήγηση από ειδικό, αφαιρέθηκε το στοιχείο της μίμησης κατά την εκπαίδευση.

Στην περίπτωση αυτή χρησιμοποιούνται τρεις διαφορετικές συναρτήσεις ανταμοιβής. Η πρώτη επιβραβεύει την επίτευξη του στόχου και την κίνηση προς αυτόν. Η δεύτερη προσθέτει ποινή σε περίπτωση σύγκρουσης, ενώ η τρίτη παρέχει επιπλέον ανταμοιβή όταν κάποιος άλλος πράκτορας φτάνει στον στόχο του.

Η συνολική συνάρτηση απώλειας διαμορφώνεται ως:

$$\mathcal{L} = \mathcal{L}_{\text{actor}} + \sigma \mathcal{L}_{\text{critic}} - \beta \mathcal{L}_{\text{entropy}} \quad (3.2)$$

Πίνακας 3.3: Συστατικά της συνάρτησης ανταμοιβής για την εκπαίδευση χωρίς καθοδήγηση

Reward Component	Value
Επίτευξη στόχου	+2.00
Κίνηση προς τον στόχο	+0.01
Κίνηση μακριά από τον στόχο	-0.01
Σύγκρουση	-0.05
Άλλος πράκτορας έφτασε στον στόχο του	+0.10

4. ΑΠΟΤΕΛΕΣΜΑΤΑ

4.1 Περιγραφή πειραματικής υποδομής

Τα πειράματα εκτελέστηκαν στο περιβάλλον Google Colab, χρησιμοποιώντας το δωρεάν πακέτο, γεγονός που καταδεικνύει τις σχετικά μικρές υπολογιστικές απαιτήσεις των προτεινόμενων μεθόδων. Συγκεκριμένα, χρησιμοποιήθηκε επεξεργαστής Intel Xeon στα 2.20 GHz με δύο εικονικούς λογικούς πυρήνες και 12 GB μνήμης RAM. Για την εκπαίδευση των μοντέλων δεν χρησιμοποιήθηκε μονάδα επεξεργασίας γραφικών (GPU).

Για κάθε πείραμα εκτελέστηκαν έως 20 000 επεισόδια. Σε περίπτωση που η εκπαίδευση δεν είχε ολοκληρωθεί, η εκτέλεση διακοπτόταν μετά από 12 ώρες, που αντιστοιχούν στο χρονικό όριο του δωρεάν πακέτου του Google Colab.

4.2 Χρήση καθοδήγησης

Αρχικά εξετάζεται κατά πόσο η χρήση καθοδήγησης από ειδικό κατά τη διάρκεια της εκπαίδευσης βελτιώνει την απόδοση των πρακτόρων. Από μια πρώτη ανάλυση προκύπτει ότι η καθοδήγηση είναι ιδιαίτερα ωφέλιμη στα αρχικά επίπεδα του curriculum, όπου διαφορετικά απαιτείται μεγάλος αριθμός επαναλήψεων μέχρι οι πράκτορες να μάθουν να προσεγγίζουν τον στόχο, ακόμη και σε περιβάλλοντα με λίγους πράκτορες και χωρίς εμπόδια.


Παρατηρείται ότι με τη χρήση καθοδήγησης ολοκληρώνονται επιτυχώς όλα τα επίπεδα του curriculum, ενώ χωρίς αυτήν το μέγιστο επίπεδο που επιτυγχάνεται είναι το 11. Επιπλέον, κατά τη διαδικασία αξιολόγησης οι πράκτορες που εκπαιδεύτηκαν με καθοδήγηση ολοκληρώνουν τα επεισόδια σε μικρότερο αριθμό βημάτων.

Στη δημοσίευση CACTUS δεν χρησιμοποιείται καθοδήγηση από ειδικό, με στόχο την αποφυγή της πρόσθετης υπολογιστικής επιβάρυνσης που συνεπάγεται ο υπολογισμός μονοπατιών. Αντίθετα, στην παρούσα εργασία χρησιμοποιείται ο αλγόριθμος Cooperative A*, ο οποίος επιτρέπει τον ιδιαίτερα γρήγορο υπολογισμό των μονοπατιών. Γενικότερα, σε εργασίες όπως τα PRIMAL και MAPPER αξιοποιείται καθοδήγηση από ειδικό, καθώς έχει παρατηρηθεί ότι χωρίς αυτήν τα ποσοστά επιτυχίας μειώνονται σημαντικά όσο αυξάνεται ο αριθμός των πρακτόρων.


Τα παραπάνω μπορούν να παρατηρηθούν στον Πίνακα 4.1, όπου, με τη χρήση καθοδήγησης και χωρίς αυτήν, φαίνονται ο αριθμός επεισοδίων για την εκπαίδευση του κάθε επιπέδου, καθώς και ο μέσος αριθμός βημάτων που χρειάζεται κάθε πράκτορας κατά τη διάρκεια της αξιολόγησης. Στα Διαγράμματα 4.1 μπορεί να παρατηρηθεί το μέσο μήκος του μονοπατιού με τη χρήση ή χωρίς τη χρήση καθοδήγησης. Στα Διαγράμματα 4.2 μπορεί να παρατηρηθεί η διαδοχή των επιπέδων όταν χρησιμοποιείται ή όχι καθοδήγηση.

Πίνακας 4.1: Μέσος αριθμός βημάτων και αριθμός επεισοδίων ανά επίπεδο με και χωρίς καθοδήγηση.

Επίπεδο	Με καθοδήγηση		Χωρίς καθοδήγηση	
	Μέσος αριθμός βημάτων	Επεισόδια	Μέσος αριθμός βημάτων	Επεισόδια
1	217	800	175	1400
2	39	1000	50	1600
3	20	1100	50	1900
4	82	1400	110	2000
5	165	1900	150	2300
6	147	2200	155	2500
7	133	2900	155	5000
8	136	4700	160	7800
9	149	6400	160	8500
10	120	8100	165	11600
11	159	11600	195	—
12	198	14600	—	—
13	120	—	—	—




(α) Με καθοδήγηση




(β) Χωρίς καθοδήγηση

Σχήμα 4.1: Μέση τιμή του μήκους του μονοπατιού μεταξύ όλων των πρακτόρων του επεισοδίου για μάθηση με καθοδήγηση και χωρίς



(α) Με καθοδήγηση



(β) Χωρίς καθοδήγηση

Σχήμα 4.2: Διαδοχή επιπέδων για μάθηση με καθοδήγηση και χωρίς

4.3 Αξιολόγηση συναρτήσεων ανταμοιβής

Εξετάστηκε επίσης η επίδραση των διαφορετικών συναρτήσεων ανταμοιβής στην εκπαίδευση των πρακτόρων. Στην περίπτωση της εκπαίδευσης με καθοδήγηση παρατηρήθηκε ότι όσο απλούστερη είναι η συνάρτηση ανταμοιβής, τόσο υψηλότερο επίπεδο καταφέρνουν να ολοκληρώσουν οι πράκτορες. Συνεπώς, η αποτελεσματικότερη συνάρτηση ανταμοιβής σε αυτήν την περίπτωση είναι εκείνη που αποδίδει μεγάλη ανταμοιβή για την επίτευξη του στόχου και μικρή ποινή σε περίπτωση σύγκρουσης με άλλον πράκτορα ή με εμπόδιο.

Αντίθετα, όταν δεν χρησιμοποιείται καθοδήγηση από ειδικό, παρατηρήθηκε ότι οι πράκτορες επωφελούνται από πιο σύνθετες συναρτήσεις ανταμοιβής. Η αποτελεσματικότερη συνάρτηση σε αυτήν την περίπτωση επιβραβεύει την επίτευξη του στόχου (+10), την επίτευξη του στόχου από άλλους πράκτορες και την κίνηση προς τον στόχο, ενώ παράλληλα επιβάλλει ποινή στις συγκρούσεις. Με τη συγκεκριμένη συνάρτηση οι πράκτορες φτάνουν έως το επίπεδο 11.

Αντίθετα, όταν χρησιμοποιείται η απλούστερη συνάρτηση ανταμοιβής, η οποία περιλαμβάνει μόνο επιβράβευση για την επίτευξη του στόχου, επιβράβευση για την κίνηση προς τον στόχο και ποινή για τις συγκρούσεις, οι πράκτορες δεν ξεπερνούν το επίπεδο 6.

Στη δημοσίευση CACTUS χρησιμοποιείται συνάρτηση ανταμοιβής που επιβάλλει ποινή για κάθε χρονικό βήμα κατά το οποίο οι πράκτορες δεν έχουν φτάσει στον στόχο. Θεωρούμε ότι, χωρίς τη χρήση καθοδήγησης από ειδικό, η επιλογή αυτή μπορεί να εισαγάγει αστάθεια κατά την εκπαίδευση και να απαιτήσει μεγάλο αριθμό επεισοδίων μέχρι οι πράκτορες να μάθουν να προσεγγίζουν τον στόχο.

Στη δημοσίευση MAPPER η συνάρτηση ανταμοιβής περιλαμβάνει τα ίδια βασικά συστατικά με αυτά που χρησιμοποιούνται στην παρούσα εργασία κατά την εκπαίδευση με καθοδήγηση, προσθέτοντας επιπλέον ποινή για την ταλάντωση μεταξύ θέσεων και για τη μη συμμόρφωση με την καθοδήγηση του ειδικού. Αντίστοιχα, στη δημοσίευση PRIMAL ακολουθείται παρόμοια προσέγγιση, με επιπλέον ποινή σε κάθε χρονικό βήμα κατά το οποίο

ένας πράκτορας δεν έχει ακόμη φτάσει στον στόχο.

Με βάση τα παραπάνω αποτελέσματα, θεωρούμε ότι η προτεινόμενη συνάρτηση ανταμοιβής αποτελεί μια ισορροπημένη επιλογή, καθώς αποφεύγει τόσο την υπεραπλούστευση του προβλήματος όσο και την παροχή υπερβολικής πληροφορίας στους πράκτορες.

Στα διαγράμματα 4.3 φαίνεται η διαδοχή των επιπέδων για τη μάθηση με καθοδήγηση, για τις διάφορες συναρτήσεις ανταμοιβής. Στα διαγράμματα 4.4 φαίνεται το μέσο μήκος του μονοπατιού για κάθε πράκτορα κατά τη διάρκεια της αξιολόγησης. Στο διάγραμμα 4.5 φαίνεται η διαδοχή των επιπέδων χωρίς τη χρήση καθοδήγησης.

4.4 Αξιολόγηση νευρωνικών δικτύων

Στη συνέχεια αξιολογήθηκαν οι διαφορετικές αρχιτεκτονικές νευρωνικών δικτύων που χρησιμοποιήθηκαν στην παρούσα εργασία. Παρατηρήθηκε ότι το LSTM, το οποίο χρησιμοποιείται και στο PRIMAL, αποτελεί την πιο απαιτητική υπολογιστικά αρχιτεκτονική. Η έκδοση που βασίζεται σε LSTM ολοκληρώνει περίπου 3 000 επεισόδια, φτάνοντας έως το επίπεδο 7.


Η προσέγγιση με χρήση GRU αποδείχθηκε υπολογιστικά ελαφρύτερη, ολοκληρώνοντας περίπου 8 000 επεισόδια και φτάνοντας έως το επίπεδο 12.

Αντίθετα, η απλούστερη αρχιτεκτονική που βασίζεται σε MLP, παρόμοια με αυτή που χρησιμοποιείται στο CACTUS, ολοκληρώνει και τα 20 000 επεισόδια, καθώς και τα 13 επίπεδα του curriculum, εντός του χρονικού ορίου των 12 ωρών.


Παρόμοια αποτελέσματα παρουσιάζει και η προσέγγιση που βασίζεται σε μηχανισμούς προσοχής (Transformers). Και σε αυτήν την περίπτωση ολοκληρώνονται επιτυχώς και τα 13 επίπεδα, ενώ εκτελούνται και τα 20 000 επεισόδια μέσα στο προκαθορισμένο χρονικό όριο. Μάλιστα, τα πειράματα ολοκληρώθηκαν σε περίπου έξι ώρες.

Με βάση τα αποτελέσματα αυτά, η χρήση μηχανισμών προσοχής αποτελεί την αποτελεσματικότερη επιλογή μεταξύ των αρχιτεκτονικών που αξιολογήθηκαν, καθώς επιτρέπει ταχύτερη πρόοδο στα επίπεδα του curriculum. Η βελτίωση αυτή αποδίδεται στην ικανότητα του μηχανισμού προσοχής να μοντελοποιεί αποτελεσματικότερα τις αλληλεπιδράσεις μεταξύ των πρακτόρων και να αξιοποιεί τη σχετική πληροφορία κατά τη λήψη αποφάσεων.


Τα παραπάνω μπορούν να παρατηρηθούν στον συγκεντρωτικό πίνακα 4.2, όπου, για κάθε νευρωνικό δίκτυο και σε κάθε επίπεδο, παρουσιάζονται το μέσο μήκος του μονοπατιού, το ποσοστό επιτυχίας κατά την τελευταία εκτέλεση αξιολόγησης σε αυτό το επίπεδο (στο τελευταίο επίπεδο παρουσιάζεται το μεγαλύτερο ποσοστό), καθώς και το μέσο σφάλμα. Επιπλέον, στα διαγράμματα 4.6 παρουσιάζεται η διαδοχή των επιπέδων για κάθε νευρωνικό δίκτυο.




(α) Επιβράβευση για την επίτευξη στόχου, την κατεύθυνση προς τον στόχο, τη συμμόρφωση με το μονοπάτι του ειδικού, την επίτευξη των στόχων από άλλους πράκτορες και ποινή για τις συγκρούσεις



(β) Επιβράβευση για την επίτευξη στόχου, την κατεύθυνση προς τον στόχο, τη συμμόρφωση με το μονοπάτι του ειδικού και ποινή για τις συγκρούσεις




(γ) Επιβράβευση για την επίτευξη στόχου τη συμμόρφωση με το μονοπάτι του ειδικού και ποινή για τις συγκρούσεις




(δ) Επιβράβευση για την επίτευξη στόχου και ποινή για τις συγκρούσεις


Σχήμα 4.3: Διαδοχή επιπέδων για μάθηση με καθοδήγηση για τις διάφορες συναρτήσεις ανταμοιβής




(α) Επιβράβευση για την επίτευξη στόχου, την κατεύθυνση προς τον στόχο, τη συμμόρφωση με το μονοπάτι του ειδικού, την επίτευξη των στόχων από άλλους πράκτορες και ποινή για τις συγκρούσεις



(β) Επιβράβευση για την επίτευξη στόχου, την κατεύθυνση προς τον στόχο, τη συμμόρφωση με το μονοπάτι του ειδικού και ποινή για τις συγκρούσεις




(γ) Επιβράβευση για την επίτευξη στόχου, τη συμμόρφωση με το μονοπάτι του ειδικού και ποινή για τις συγκρούσεις




(δ) Επιβράβευση για την επίτευξη στόχου και ποινή για τις συγκρούσεις


Σχήμα 4.4: Μέση τιμή του μήκους του μονοπατιού μεταξύ όλων των πρακτόρων του επεισοδίου για μάθηση με καθοδήγηση για τις διάφορες συναρτήσεις ανταμοιβής



(α) Επιβράβευση της επίτευξης στόχου




(β) Επιβράβευση της επίτευξης στόχου, εάν άλλος πράκτορας φτάσει στον στόχο, εάν η κίνηση φέρνει τον πράκτορα πιο κοντά στον στόχο και επιβολή ποινής εάν υπάρξει σύγκρουση




(γ) Επιβράβευση της επίτευξης στόχου, εάν η κίνηση φέρνει τον πράκτορα πιο κοντά στον στόχο και επιβολή ποινής εάν υπάρξει σύγκρουση


Σχήμα 4.5: Διαδοχή επιπέδων για μάθηση χωρίς καθοδήγηση




(α) Χρήση LSTM



(β) Χρήση GRU



(γ) Χρήση MLP



(γ) Χρήση Transformers

Σχήμα 4.6: Εναλλαγή επιπέδων με τη χρήση διαφορετικών νευρωνικών δικτύων


4.5 Αξιολόγηση αλγορίθμων Βαθιάς Ενισχυτικής Μάθησης

Τέλος, αξιολογήθηκε η επίδραση του αλγορίθμου Βαθιάς Ενισχυτικής Μάθησης στην απόδοση των προτεινόμενων προσεγγίσεων. Παρατηρήθηκε ότι ο αλγόριθμος A2C οδηγεί σε ταχύτερη εκπαίδευση και επιτρέπει την επιτυχή ολοκλήρωση και των 13 επιπέδων του curriculum, τόσο με τη χρήση MLP όσο και με τη χρήση μηχανισμών προσοχής (Transformers).

Σε όλα τα προηγούμενα πειράματα χρησιμοποιήθηκε ο αλγόριθμος A2C, καθώς παρουσίασε την καλύτερη συνολική απόδοση. Αντίθετα, κατά τη χρήση του αλγορίθμου PPO παρατηρήθηκε ότι ο περιορισμός στις μεταβολές της πολιτικής μεταξύ διαδοχικών ενημερώσεων δυσχεραίνει την αντιμετώπιση καταστάσεων συμφόρησης (bottlenecks), με αποτέλεσμα οι πράκτορες να εξαντλούν συχνά τον μέγιστο επιτρεπόμενο αριθμό ενεργειών χωρίς να καταφέρνουν να επιλύσουν το πρόβλημα.

Ως συνέπεια, με τον PPO ολοκληρώνονται επιτυχώς τα 12 από τα 13 επίπεδα του curriculum και περίπου 19 000 από τα 20 000 επεισόδια εκπαίδευσης.

Τα διαγράμματα 4.7 παρουσιάζουν τη διαδοχή των επιπέδων για τους αλγορίθμους PPO και A2C.



Σχήμα 4.7: Εναλλαγή επιπέδων με τη χρήση των αλγορίθμων A2C και PPO


4.6 Απώλεια και Επιστροφή

Η συνάρτηση απώλειας μειώνεται ραγδαία κατά τα πρώτα 2 000 επεισόδια της εκπαίδευσης. Στη συνέχεια παρατηρούνται απότομες αυξήσεις κατά τη μετάβαση σε επίπεδα μεγαλύτερης δυσκολίας, όπως στο επίπεδο 7 (περίπου στο επεισόδιο 2 500), οι οποίες όμως μειώνονται σταδιακά καθώς οι πράκτορες προσαρμόζονται στο νέο επίπεδο. Γενικά, η απώλεια παραμένει σχετικά σταθερή στο μεγαλύτερο μέρος της εκπαίδευσης, με εξαίρεση το επίπεδο 13 (μετά το επεισόδιο 14 700), όπου εμφανίζονται σημαντικές διακυμάνσεις.


Όσον αφορά τη μέση επιστροφή, η χρήση καθοδήγησης από ειδικό οδηγεί σε ταχεία αύξησή της κατά τα πρώτα 2 000 επεισόδια, καθώς τα αρχικά επίπεδα είναι σχετικά απλά και

οι πράκτορες μαθαίνουν γρήγορα να ακολουθούν την καθοδήγηση. Στη συνέχεια, καθώς αυξάνεται η δυσκολία των επιπέδων, παρατηρούνται απότομες μειώσεις, κυρίως κατά τη μετάβαση σε νέο επίπεδο. Ωστόσο, η μέση επιστροφή παραμένει γενικά σταθερή, κυμαινόμενη μεταξύ 0.75 και 0.85. Εξαίρεση αποτελούν και εδώ τα δύο τελευταία επίπεδα, στα οποία εμφανίζονται σημαντικές διακυμάνσεις.

Παρακάτω παρατίθενται διαγράμματα για την απώλεια κατά τη διάρκεια των δοκιμών (διάγραμμα 4.8) και τη μέση επιστροφή (διάγραμμα 4.9) κατά τη χρήση Transformers και A2C.



Σχήμα 4.8: Απώλεια κατά τη διάρκεια των δοκιμών με τη χρήση Transformer και A2C



Σχήμα 4.9: Μέση επιστροφή από την αξιολόγηση με τη χρήση Transformer και A2C

Πίνακας 4.2: Σύγκριση των νευρωνικών δικτύων ανά επίπεδο

Level	LSTM			GRU			Transformer			MLP		
	E	SR	Err	E	SR	Err	E	SR	Err	E	SR	Err
1	210	100%	0.7817	190	90%	1.3106	217	80%	0.6261	189	80%	0.6921
2	10	100%	0.3792	35	100%	0.2828	39	100%	0.1684	10	100%	0.1126
3	12	90%	0.1026	15	90%	-0.0157	20	100%	0.2352	16	100%	0.2965
4	15	90%	0.0404	15	90%	0.0850	82	80%	0.0429	67	90%	0.1606
5	140	80%	0.0361	145	80%	0.0293	165	80%	-0.0033	156	80%	0.0616
6	140	90%	0.0216	125	80%	0.0019	147	90%	0.0065	170	80%	0.0111
7	130	70%	0.2625	120	90%	1.4335	133	80%	1.0447	125	80%	0.6479
8	—	—	—	110	80%	0.3098	136	90%	0.0981	130	80%	0.1747
9	—	—	—	120	80%	0.0454	149	80%	0.0857	140	100%	0.1022
10	—	—	—	145	90%	0.2426	120	80%	0.3621	100	80%	0.1207
11	—	—	—	145	80%	0.2753	159	90%	0.1676	148	80%	0.2176
12	—	—	—	175	60%	0.1001	198	80%	0.1309	188	80%	0.1055
13	—	—	—	—	—	—	120	80%	0.2505	84	80%	0.2442

E: Μέσο μήκος μονοπατιού, SR: Success Rate, Err: Μέσο σφάλμα.

5. ΣΥΜΠΕΡΑΣΜΑΤΑ ΚΑΙ ΜΕΛΛΟΝΤΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ

Στην παρούσα διπλωματική εργασία εξετάστηκε η αλληλεπίδραση διαφορετικών αρχιτεκτονικών νευρωνικών δικτύων με το Curriculum Learning στο πρόβλημα του Multi-Agent Path Finding (MAPF), ακολουθώντας μια αλγοριθμική ροή παρόμοια με εκείνη του PRIMAL. Η προσέγγιση αυτή οδήγησε στη χρήση μηχανισμών προσοχής (Transformers) για την επικοινωνία και την καθοδήγηση των πρακτόρων. Επιπλέον, πραγματοποιήθηκε διαδικασία βελτιστοποίησης, κατά την οποία αξιολογήθηκαν διαφορετικές συναρτήσεις ανταμοιβής, συγκρίθηκαν οι αλγόριθμοι A2C [11] και PPO [12] και διερευνήθηκε κατά πόσο η χρήση του Imitation Learning επιταχύνει την εκπαίδευση των πρακτόρων.

Τα αποτελέσματα της αξιολόγησης έδειξαν ότι η χρήση καθοδήγησης από ειδικό επιταχύνει σημαντικά την εκπαίδευση, μειώνοντας τον αριθμό των βημάτων που απαιτούνται για την επίτευξη του στόχου. Επιπλέον, με τη χρήση καθοδήγησης ολοκληρώνονται επιτυχώς και τα 13 επίπεδα του curriculum, ενώ χωρίς αυτήν οι πράκτορες φτάνουν έως το επίπεδο 11. Από την αξιολόγηση των διαφορετικών συναρτήσεων ανταμοιβής προέκυψε ότι, όταν χρησιμοποιείται καθοδήγηση από ειδικό, οι απλούστερες συναρτήσεις ανταμοιβής οδηγούν σε καλύτερη απόδοση. Αντίθετα, όταν δεν χρησιμοποιείται καθοδήγηση, απαιτούνται πιο σύνθετες συναρτήσεις ανταμοιβής ώστε οι πράκτορες να εκπαιδευτούν αποτελεσματικά.

Όσον αφορά τις αρχιτεκτονικές των νευρωνικών δικτύων, η υλοποίηση με LSTM αποδείχθηκε η πιο απαιτητική υπολογιστικά, ενώ η αντίστοιχη υλοποίηση με GRU παρουσίασε μικρότερες υπολογιστικές απαιτήσεις μεταξύ των επαναλαμβανόμενων νευρωνικών δικτύων. Οι αρχιτεκτονικές που βασίζονται σε MLP και Transformers παρουσίασαν τη συνολικά καλύτερη απόδοση, ολοκληρώνοντας επιτυχώς όλα τα επίπεδα του curriculum. Ιδιαίτερα η προσέγγιση με χρήση Transformers ολοκλήρωσε την εκπαίδευση σε περίπου οκτώ ώρες.

Από τη σύγκριση των αλγορίθμων Βαθιάς Ενισχυτικής Μάθησης διαπιστώθηκε ότι ο A2C παρουσιάζει καλύτερη απόδοση από τον PPO, καθώς ολοκληρώνει επιτυχώς και τα 13 επίπεδα του curriculum. Αντίθετα, η μεγαλύτερη σταθερότητα που επιβάλλει ο PPO στις ενημερώσεις της πολιτικής φαίνεται να δυσχεραίνει την αντιμετώπιση πολύπλοκων καταστάσεων, με αποτέλεσμα να μην ολοκληρώνεται το τελευταίο επίπεδο. Τέλος, παρατηρήθηκε ότι τόσο η συνάρτηση απώλειας όσο και η μέση επιστροφή παραμένουν γενικά σταθερές κατά τη διάρκεια της εκπαίδευσης, με εξαίρεση τα αρχικά επίπεδα, τις μεταβάσεις σε επίπεδα αυξημένης δυσκολίας και τα τελευταία δύο επίπεδα, όπου εμφανίζονται σημαντικές διακυμάνσεις.

Μελλοντική επέκταση της παρούσας εργασίας θα μπορούσε να περιλαμβάνει την εκτέλεση των πειραμάτων σε ισχυρότερη υπολογιστική υποδομή, με χρήση GPU και μεγαλύτερης χωρητικότητας μνήμης RAM, ώστε να καταστεί δυνατή η εκπαίδευση σε περιβάλλοντα με περισσότερους πράκτορες και εμπόδια. Επιπλέον, ενδιαφέρον παρουσιάζει η αξιοποίηση μοντέλων διάχυσης (diffusion models) για την εκπαίδευση πρακτόρων μέσω Ενισχυτικής Μάθησης [31]. Μια ακόμη πιθανή κατεύθυνση είναι η χρήση εργαλείων αυτόματης βελτιστοποίησης υπερπαραμέτρων, όπως το Optuna [32]. Τέλος, θα μπορούσε να διερευνηθεί η χρήση πιο σύνθετων αλγορίθμων σχεδιασμού μονοπατιών, όπως οι LaCAM [7] και LNS

[6], για την καθοδήγηση των πρακτόρων σε συνδυασμό με αρχιτεκτονικές βασισμένες σε Transformers.


ΣΥΝΤΜΗΣΕΙΣ – ΑΡΚΤΙΚΟΛΕΞΑ – ΑΚΡΩΝΥΜΙΑ

AI	Artificial Intelligence
MAPF	Multi Agent Path Finding
LSTM	Long Short Term Memory
GRU	Gated Recurrent Unit
CBS	Conflict-based Search
PBS	Priority Based Search
LNS	Large Neighborhood Search
LaCAM	Lazy Constraints Addition search for MAPF
RL	Reinforcement Learning
MARL	Multi Agent Reinforcement
MDP	Markovian Decision Process
PRIMAL	Pathfinding via Reinforcement and Imitation Multi-Agent Learning
MAPPER	Multi-Agent Path Planning with Evolutionary Reinforcement Learning in Mixed Dynamic Environments
EPH	Ensembling Prioritized Hybrid Policies for Multi-agent Pathfinding
CRAMP	Optimizing Crowd-Aware Multi-Agent Path Finding through Local Communication with Graph Neural Networks
ALPHA	Attention-based Long-horizon Pathfinding in Highly-structured Areas
MLP	Multi Layer Perceptron
FNN	Feed Forward Neural Network
CNN	Convolutional Neural Network
GNN	Graph Neural Network
A3C	Asynchronous Advantage Actor-Critic


A2C	Advantage Actor-Critic
PPO	Proximal Policy Optimization

ΟΠΤΙΚΟΠΟΙΗΣΗ ΤΩΝ ΕΠΙΠΕΔΩΝ


Παρακάτω παρουσιάζουμε οπτικές αναπαραστάσεις των διαφορετικών πλεγμάτων που καλούνται να λύσουν οι πράκτορες.



Σχήμα 1: Επίπεδο 1 - Ένας πράκτορας χωρίς εμπόδια




Σχήμα 2: Επίπεδο 2 - Δύο πράκτορες χωρίς εμπόδια




Σχήμα 3: Επίπεδο 3 - Τέσσερις πράκτορες χωρίς εμπόδια







Σχήμα 6: Επίπεδο 6 - Τριανταδύο πράκτορες χωρίς εμπόδια




Σχήμα 7: Επίπεδο 7 - Δύο πράκτορες με εμπόδια στο 10% του πλέγματος




Σχήμα 8: Επίπεδο 8 - Τέσσερις πράκτορες με εμπόδια στο 10% του πλέγματος




Σχήμα 9: Επίπεδο 9 - Οκτώ πράκτορες με εμπόδια στο 10% του πλέγματος




Σχήμα 10: Επίπεδο 10 - Δύο πράκτορες με εμπόδια στο 20% του πλέγματος



Σχήμα 11: Επίπεδο 11 - Τέσσερις πράκτορες με εμπόδια στο 20% του πλέγματος



Σχήμα 12: Επίπεδο 12 - Οκτώ πράκτορες με εμπόδια στο 20% του πλέγματος



Σχήμα 13: Επίπεδο 13 - Δύο πράκτορες με εμπόδια στο 30% του πλέγματος

ΑΝΑΦΟΡΕΣ

- [1] G. Sartoretti, J. Kerr, Y. Shi, G. Wagner, T. K. S. Kumar, S. Koenig, and H. Choset, “Primal: Pathfinding via reinforcement and imitation multi-agent learning,” *IEEE Robotics and Automation Letters*, vol. 4, no. 3, p. 2378–2385, 2019. [Online]. Available: <http://dx.doi.org/10.1109/LRA.2019.2903261>
- [2] R. Stern, N. Sturtevant, A. Felner, S. Koenig, H. Ma, T. Walker, J. Li, D. Atzmon, L. Cohen, T. K. S. Kumar, E. Boyarski, and R. Bartak, “Multi-agent pathfinding: Definitions, variants, and benchmarks,” in *Proceedings of the Twelfth International Symposium on Combinatorial Search*, Napa, California, USA, 2019.
- [3] S. Wang, H. Xu, Y. Zhang, J. Lin, C. Lu, X. Wang, and W. Li, “Where paths collide: A comprehensive survey of classic and learning-based multi-agent pathfinding,” 2025. [Online]. Available: <https://arxiv.org/abs/2505.19219>
- [4] G. Sharon, R. Stern, A. Felner, and N. Sturtevant, “Conflict-based search for optimal multi-agent path finding,” in *Proceedings of the Twenty-Sixth AAAI Conference on Artificial Intelligence*, Toronto, Ontario, Canada, 2012.
- [5] M. Phillips and M. Likhachev, “Sipp: Safe interval path planning for dynamic environments,” in *2011 IEEE International Conference on Robotics and Automation*, 2011, pp. 5628–5635.
- [6] J. Li, Z. Chen, D. Harabor, P. J. Stuckey, and S. Koenig, “Anytime multi-agent path finding via large neighborhood search,” in *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*, 2021, pp. 4127–4135.
- [7] K. Okumura, “Lacam: Search-based algorithm for quick multi-agent pathfinding,” in *Proceedings of AAAI Conference on Artificial Intelligence (AAAI)*, 2023.
- [8] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*, 2nd ed. MIT press, 2018.
- [9] S. V. Albrecht, F. Christianos, and L. Schäfer, *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches*. MIT Press, 2024. [Online]. Available: <https://www.marl-book.com>
- [10] S. J. Prince, *Understanding Deep Learning*. The MIT Press, 2023. [Online]. Available: <http://udlbook.com>
- [11] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Harley, T. P. Lillicrap, D. Silver, and K. Kavukcuoglu, “Asynchronous methods for deep reinforcement learning,” in *Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48*, ser. ICML’16. JMLR.org, 2016, p. 1928–1937.
- [12] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” 2017. [Online]. Available: <https://arxiv.org/abs/1707.06347>
- [13] M. Damani, Z. Luo, E. Wenzel, and G. Sartoretti, “Primal₂: Pathfinding via reinforcement and imitation multi-agent learning - lifelong,” *IEEE Robotics and Automation Letters*, vol. 6, no. 2, p. 2666–2673, Apr. 2021. [Online]. Available: <http://dx.doi.org/10.1109/LRA.2021.3062803>
- [14] T. Phan, J. Driscoll, J. Romberg, and S. Koenig, “Curriculum learning for multi-agent path finding,” in *International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2024.
- [15] Z. Liu, B. Chen, H. Zhou, G. Koushik, M. Hebert, and D. Zhao, “Mapper: Multi-agent path planning with evolutionary reinforcement learning in mixed dynamic environments,” in *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2020, pp. 11 748–11 754.
- [16] H. Tang, F. Berto, and J. Park, “Ensembling prioritized hybrid policies for multi-agent pathfinding,” in *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2024, pp. 8047–8054.

- [17] P. Pham and A. Bera, “Optimizing crowd-aware multi-agent path finding through local communication with graph neural networks,” in *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, Oct. 2024, p. 8913–8913. [Online]. Available: <http://dx.doi.org/10.1109/IROS58592.2024.10801969>
- [18] C. He, T. Yang, T. Duhan, Y. Wang, and G. Sartoretti, “Alpha: Attention-based long-horizon pathfinding in highly-structured areas,” in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024, pp. 14 576–14 582.
- [19] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [20] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, “Empirical evaluation of gated recurrent neural networks on sequence modeling,” in *NIPS 2014 Deep Learning and Representation Learning Workshop*, 2014.
- [21] K. Cho, B. van Merriënboer, D. Bahdanau, and Y. Bengio, “On the properties of neural machine translation: Encoder–decoder approaches,” in *Proceedings of SSST-8, Eighth Workshop on Syntax, Semantics and Structure in Statistical Translation*, D. Wu, M. Carpuat, X. Carreras, and E. M. Vecchi, Eds. Doha, Qatar: Association for Computational Linguistics, Oct. 2014, pp. 103–111. [Online]. Available: <https://aclanthology.org/W14-4012/>
- [22] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17. Red Hook, NY, USA: Curran Associates Inc., 2017, p. 6000–6010.
- [23] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021. [Online]. Available: <https://openreview.net/forum?id=YicbFdNTTy>
- [24] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, “Swin transformer: Hierarchical vision transformer using shifted windows,” in *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 9992–10 002.
- [25] A. Andreychuk, K. Yakovlev, A. Panov, and A. Skrynnik, “Mapf-gpt: imitation learning for multi-agent pathfinding at scale,” in *Proceedings of the Thirty-Ninth AAAI Conference on Artificial Intelligence and Thirty-Seventh Conference on Innovative Applications of Artificial Intelligence and Fifteenth Symposium on Educational Advances in Artificial Intelligence*, ser. AAAI’25/IAAI’25/EAAI’25. AAAI Press, 2025. [Online]. Available: <https://doi.org/10.1609/aaai.v39i22.34477>
- [26] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, *PyTorch: an imperative style, high-performance deep learning library*. Red Hook, NY, USA: Curran Associates Inc., 2019.
- [27] A. Skrynnik, A. Andreychuk, A. Borzilov, A. Chernyavskiy, K. Yakovlev, and A. Panov, “Pogema: A benchmark platform for cooperative multi-agent pathfinding,” in *The Thirteenth International Conference on Learning Representations*, 2025.
- [28] J. Chung, Ç. Gülçehre, K. Cho, and Y. Bengio, “Empirical evaluation of gated recurrent neural networks on sequence modeling,” *CoRR*, vol. abs/1412.3555, 2014. [Online]. Available: <http://arxiv.org/abs/1412.3555>
- [29] C. Ferner, G. Wagner, and H. Choset, “Odrm* optimal multirobot path planning in low dimensional search spaces,” in *2013 IEEE International Conference on Robotics and Automation*, 2013, pp. 3854–3859.
- [30] D. Silver, “Cooperative pathfinding,” in *Proceedings of the First AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, ser. AIIDE’05. AAAI Press, 2005, p. 117–122.

- [31] Y. Zhang, E. Tzeng, Y. Du, and D. Kislyuk, “Large-scale reinforcement learning for diffusion models,” 2024. [Online]. Available: <https://arxiv.org/abs/2401.12244>
- [32] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, ser. KDD ’19. New York, NY, USA: Association for Computing Machinery, 2019, p. 2623–2631. [Online]. Available: <https://doi.org/10.1145/3292500.3330701>